

DisasterTrace

动态天气证据中的 LLM 状态与来源追踪

当资料持续更新，模型能否持续给出
与目标相匹配、并由当前来源支持的答案？

内容

数值与状态是否正确

来源

依据是否对准目标与版本

过程

能否整段并重复成功

天气资料连续发布，查询目标需要保持明确

发行时刻与目标有效时刻不同；模型需要对齐同一个问题。

固定问题：这个风暴在指定未来时刻，最新明确陈述支持什么？

连续公告

相同机构
不同发行时刻
逐步交付给模型

目标对齐

相同风暴
相同绝对有效时刻
相同变量与测量种类

更新行为

有新覆盖时更新
缺少支持时留空
其他目标保持区分

因此，评测单位需要包含证据变化的过程。

同一个正确数字，可以对应不同的证据行为

教学示例：R2 明确替代 R1；两个版本对目标 A 都写 60 mph。

材料：R1 / A / 60 → R2 / A / 60；随后出现另一个目标 B / 100

答案 60 + 引用 R2

内容正确
目标匹配
当前来源正确

答案 60 + 引用 R1

内容正确
旧记录仍有字面支持
当前版本选择失败

答案 100 + 引用 B

文本中确有这个数值
但不属于目标 A
作用域或数值错误

只核对数值，无法区分前两种行为。

相关研究提供基础，本文明确具体测量组合

知识更新、过期状态、引用与重复可靠性均已有直接研究。

研究方向	相关工作	已有基础	本项目的具体落点
天气事件验证	Extreme Weather Bench	事件、预报与观测	天气资料使用与目标时间
答案与引用	ALCE	内容与引用分层	可定位引用及当前版本
知识与状态更新	LongMemEval StateMemBench / STALE	时间、更新、过期状态	同对象、同有效时间的修订
重复可靠性	tau-bench	跨重复成功表现	完整更新轨迹的重复成功

贡献候选：将目标时间、当前来源与多轮可靠性组织成可复算任务。

三个研究问题决定任务与实验

每个问题都有对应证据；原生模型结论仍需完成采集与核验。

RQ1

内容正确是否代表证据使用正确？

同一字段分母上，分开值/状态、字面支持和当前来源。

RQ2

无关信息加入后，模型能否持续可靠？

配对条件、三种历史配置、完整轨迹与两次重复。

RQ3


测量要求能否在官方原文上成立？

先验证目标对齐与公开可解性，再获取原生模型证据。

接下来先定义统一的输入、答案和评分对象。

统一接口：目标、可见证据、历史与可核验答案

查询键明确对象、有效时间、变量、测量种类与单位。



历史来自实际模型输出；语义错误不会被参考答案修正。

受控诊断与官方原文承担互补的验证任务

统一问题与测量框架，分别保留材料、语义和结果。

受控更新诊断

为什么需要：明确控制应变与不应变

局部更新、作用域、同值修订、支持恢复
真实来源初值 + 明确生成的后续变化

提供：可解释的模型行为诊断

官方预报原文

为什么需要：检验自然资料中的对应结构

真实发行顺序、时效网格、覆盖缺口
完整官方文本 + 原生终止陈述

提供：现实材料上的任务与后续模型证据

受控实验的诊断清晰度，与原生资料的现实约束共同构成 benchmark。

自动评分建立在明确语义与独立验证上

无需新增逐题人工标注，意味着先限定可自动验证的任务范围。

01 保存与准入

原始资料、来源、哈希
解析歧义留在隔离记录



02 编译与公开求解

编译参考答案
从可见文本独立重求



03 程序对照

正确策略与错误捷径
无效、缺失均保留机会

04 冻结模型执行

题目、方法、预算与身份
实际历史逐轮构造请求



05 评分与归因

内容、目标、版本、定位
检查点及完整轨迹



06 独立重建

从原始捕获恢复请求
复算完整分母与结果

程序一致性增强可复核性；任务政策及适用范围仍需研究者审查。

三种历史配置比较模型如何使用已有答案

所有配置都能重新读取截至当前累计交付的原始证据。

输入配置	累计原始证据	额外模型历史
仅证据 snapshot	全部可见	不附加历史答案
上轮状态 structured_state	全部可见	上一份结构合法的完整模型答案
全部历史 answer_history	全部可见	此前全部结构合法的模型答案

真实语义错误原样传递；配置差异同时涉及信息量、表示、长度和错误携带。

这些是实验条件；当前比较不隔离模型内部的单一记忆机制。

实验按研究问题组织，结果按证据层级报告

统一研究主线，不把不同材料和阶段合成一个总分。

RQ1 / RQ2：已验收的受控模型实验

36 基础 episode × 5 检查点
× 2 条件 × 3 方法 × 2 重复 = 2,160 回答

固定 Qwen3-8B；仅 3 个独立来源组

RQ3：官方原文任务验证

12 公告 → 46 目标 → 257 查询
九种程序策略已完成


1,542 个模型机会正在采集

结构约束用于单独测量形式交付可靠时的语义表现；
参考答案不参与解码，格式合法仍可能内容或引用错误。

先解释测量对象，再解释分数；回答数不等于独立天气事件数。

发现一： 值正确仍会掩盖版本追踪失败

同一字段分母：8,640 个机会，避免把不同粒度的差额混为一谈。



条形长度从 0% 起；两个指标使用相同字段分母。

真实模型例子：答案和参考都为 60 mph，模型仍引用已被替代的旧记录。

记录存在、定位合法、目标匹配、数值有字面支持；失败是当前来源选择。


RQ1：内容正确与来源版本正确，在实测中确实可以分离。

发现二：单点高分不等于重复整段可靠

同一个上轮状态方法；每个指标直接计算实际成功事件。


检查点全对

分母：每条件 360 次回答




五轮全对

分母：每条件 72 条轨迹



两次均五轮全对

分母：每条件 36 个 episode



RQ2: 96.9% → 88.6% 的单点表现，对应 83.3% → 41.7% 的重复整段成功。

历史配置表现不同，机制解释需要额外控制

曝光后配对每方法 216 对；保留改善和退化两个方向。

方法	基础全对 /360	干扰全对 /360	仅基础对 曝光后 /216	仅干扰对 曝光后 /216
仅证据	340, 94.4%	309, 85.8%	45	14
上轮状态	349, 96.9%	319, 88.6%	37	7
全部历史	279, 77.5%	265, 73.6%	38	24

干扰前 c0/c1：432 对请求与最终文本相同，且两边都正确。
上轮状态在当前设置中最高；长度、信息量与历史错误尚未单独隔离。

RQ2：当前支持条件性的配置比较；表示形式的因果解释需要匹配实验。

官方原文提供真实的时间对齐与覆盖变化

固定目标：Francine / 2024-09-10 18:00 UTC / 最大持续风速。

公告 005 / 09-09 21:00

75 KT

明确覆盖目标

公告 006 / 09-10 03:00

无明确目标行

本任务保留此前明确陈述

公告 007 / 09-10 09:00

70 KT

新的同目标明确预报

最新明确覆盖是已发布陈述的选择政策；它不证明被省略的旧预报在业务上仍然有效。

1,542 / 1,542

公开求解器：完整正确

606 / 1,542

错用相对时效：完整正确

72 / 1,542

选最后一行：完整正确

RQ3 已有证据：自然资料可构成可解、有区分度的任务；模型验证进行中。

整体进展： 测量已成立，原生模型证据正在补齐

按 benchmark 的组成部分定位成熟度，而非按开发编号逐项汇报。

组成部分	完成度	可以支持的表述
来源与两类任务	已建立	受控更新 + 官方原文，范围与语义明确
公开求解与确定性评分	已验证	可解性、失败分类与固定分母可复算
受控模型实验	已独立验收	2,160 实际回答；内容、引用与轨迹分析
原生任务程序验证	已离线验收	257 查询、九种程序对照
原生模型采集	四 worker 运行中	CPU 与 H100 预检已过；模型成绩待验收

当前是有实证支撑的研究型 benchmark 原型；外推验证继续补充。

贡献落在任务、测量与实证，并明确适用范围

贡献表述与已有证据匹配；论文新颖性仍需完整近邻比较。

已有证据支持的贡献

任务	显式目标、版本与交付语义 受控诊断和官方原文任务
测量	内容、当前来源、连续可靠分层 自动参考、公开求解、独立重建
实证	值正确仍可引用旧版本 局部高分仍可对应较低整段成功

当前结论的适用边界

模型与事件	来源较少，模型比较尚不充分 不能把回答数当独立事件数
任务效度	政策明确但范围有限 不是实际预报技巧或业务价值验证
机制解释	历史信息量、长度和错误共同变化 纯表示与内部机制尚未隔离

重点是明确测到了什么，以及还有哪些结论需要新的证据。

后续实验逐一解决尚未回答的问题

从已有结果的限制出发安排工作，保持每一步的研究目的清楚。

1 / 原生模型核验

问题：受控发现是否在自然资料中出现？

完成当前采集与独立重算
分别报告值、引用、轨迹
保留缺失和失败机会

2 / 匹配载体实验

问题：配置差异来自哪些因素？

固定证据与同一保存前缀
保持信息与已有错误相同
分别控制表示及 token 长度

3 / 匹配模型与事件

问题：结论能外推到什么范围？

同协议加入第二模型
预定规则扩展独立事件
再设计跨灾种或多模态任务

新的工作应增加可解释的研究证据；GPU 并行只解决已定义矩阵的计算速度。

同时测量内容、当前依据与连续表现

DisasterTrace 将持续更新的天气证据使用转化为可执行的评测。

内容

状态与数值是否正确

当前依据

来源是否对准目标与版本

连续表现

整段更新是否反复成功

当前实测表明，这三个层面并不等价。
两个互补任务为诊断失败与验证自然资料中的表现提供共同框架。

下一项关键证据：原生模型结果，以及更多模型和独立事件上的匹配验证。

附录 A：早期资产与开发阶段如何归入整体

阶段编号用于追溯；主讲中的论证由研究问题组织。

资产或阶段	研究中的作用	边界
DisasterBench / CyPortQA	继承规划适配、题型与原文入口	230 规划任务；48 模板 profile 非 QA 数
NHC cohort / P1 / T6	来源划分、服务交付与预算校准	不同矩阵不能组成统一排行榜
P2 / P3 / P4	受控语义；自由/结构约束分轨	不等于训练提升或旧答案修复
P5 / P6	固定压力；配对、重复、来源归因	受控后续变化明确由程序构造
原生 task / live	自然资料任务、程序验证、模型采集	工程验收与模型成绩分别标注

附录 B：受控主实验的完整方法结果

不同可靠性指标使用不同分母；当前只含三个独立来源组。

条件	方法	R0 /180	R1 /180	检查点全对	五轮全对	两次均全对
基础	仅证据	171	169	340/360	55/72	22/36
基础	上轮状态	171	178	349/360	64/72	30/36
基础	全部历史	144	135	279/360	37/72	13/36
干扰	仅证据	152	157	309/360	31/72	11/36
干扰	上轮状态	157	162	319/360	43/72	15/36
干扰	全部历史	139	126	265/360	34/72	10/36

完整正确：1,861/2,160；字段错误 382，错误回答 299，43 个动作错误与字段错误重叠。

附录 C：常见质疑与当前可回答的范围

将测量目标、领域意义和因果解释分别说清楚。

问题	当前回答
程序能满分，为何评测 LLM？	程序证明公开可解，并提供参照。研究测量 LLM 使用资料时的可靠性；不据此推荐用 LLM 替代可用的专用解析器。
为什么数字对却扣引用分？	当前来源是公开任务要求；同时报告数值与引用分数。旧来源有字面支持，不等于满足任务的当前版本要求。
天气领域贡献是什么？	原生时间网格、目标有效时刻、风速/阵风、覆盖和终止状态。受控部分也含通用状态追踪；跨领域显示对照尚待补充。
结构化历史是否更优？	当前配置中上轮状态最高，但信息、长度与历史错误同时变化。需要相同前缀和证据的匹配对照，再讨论表示或机制。

附录 D：参考与证据入口

本次核对原始论文页面及摘要；既有方案提供实现核查记录。

文献	在本叙事中的作用	原始入口
R1 / ALCE	答案正确性与引用质量	aclanthology.org/2023.emnlp-main.398
R2 / LongMemEval	知识更新、时间推理与拒答	arxiv.org/abs/2410.10813
R3 / StateMemBench	当前与被替代状态	arxiv.org/abs/2608.19652v1
R4 / STALE	过期记忆与后续行为	arxiv.org/abs/2605.06527v1
R5 / tau-bench	重复可靠性	arxiv.org/abs/2406.12045
R6 / Extreme Weather Bench	高影响天气事件验证	arxiv.org/abs/2605.01126

完整逻辑、逐页讲稿、转场、限制及阶段映射均在配套 Markdown 中。