

新增证据延伸了同一个研究问题

当天气证据持续更新，LLM 能否持续给出目标正确、来源当前的答案？

受控诊断 为什么需要分层测量

2,160 份已有模型回答
内容正确仍可能引用旧版

解释值、来源与整段可靠性
为何必须分别评估

官方原文 现在已有真实模型结果

两风暴 Qwen 收齐 1,542 份
严格正确 527 份

再扩六个风暴、36 份原文
检验事件与状态差异

比较诊断 进一步解释分数来源

422 对同前缀表示实验
第二本地模型与协议对照

历史增长、故障牵连与缺失
成为后续测量的重点

当前测量对象：对已发布天气陈述的理解、更新与引用。

官方原文上，结构合法仍远不足以保证正确

两风暴 · 46 个目标 · 257 个检查点 · 三种历史条件 · 两次重复

全部返回且结构合法

1,542 / 1,542

目标键、单位字符串也全部正确

严格正确：34.18%

527 / 1,542

失败不能统一归因于 JSON 格式

错误分解	失败检查点数	口径
值／状态失败	764	本组中单位实际均正确
定位／版本／同值旧版	223 + 23 + 5 = 251	引用相关的互斥错误类别

互斥失败合计 1,015；不要与允许重叠的组件失败计数相加。

局部答对，不等于整个目标持续可靠

276 条轨迹中，仅 19 条所有检查点都正确；进一步要求两次均成功的目标更少。

历史条件	检查点严格正确	两次均整段正确
snapshot	187 / 514 = 36.38%	1 / 46
structured_state	194 / 514 = 37.74%	2 / 46
answer_history	146 / 514 = 28.40%	2 / 46

Francine 与 Ida 上，snapshot 和 structured_state 的领先顺序相反。

两风暴的描述性结果支持多层测量，尚不足以形成通用方法排名。

固定同一历史前缀，再比较载体表示

422 个非初始前缀，每个分别生成 JSON／文本两个单步分支，共 844 份回答。

配对结果	文本正确	文本错误
JSON 正确	88	30
JSON 错误	55	249

JSON 27.96% → 文本 33.89%

118 / 422 → 143 / 422
增加 25 个正确回答，+5.92 个百分点
保留相同历史信息与已有错误

文本每个请求多 36—54 token，平均多 47.34；没有等长度配对。
观测的是具体表示方案的差异，包括语法和长度。

可解释为这些前缀上的单步差异，不能推广为纯格式效应或完整轨迹收益。

扩展真实事件，同时检查常见捷径是否有效

Dorian、Isaias、Henri、Fiona、Lee、Helene；各取最初六份编号公告。

36	144	804	2,412
原始公告	绝对时间目标	纳入未来检查点	每模型／协议回答机会

公开程序策略	正确／2,412	说明
latest_explicit	2,412	规则可公开求解
最新公告 / 同相对时长	1,434 / 1,020	两类捷径均不等价于目标时间对齐
最后一行	108	资料中可见不等于属于当前目标

六个早期公告队列；有终止状态，但没有终止修订检查点。

同一组结果，不同指标给出不同的方法排序

六风暴 Qwen，system／任意空白条件已全部收齐；只有一次重复。

历史条件	检查点正确／804	整目标正确／144
snapshot	356 · 单点最多	4
structured_state	345	22 · 整目标最多
answer_history	299	15

默认空白条件：snapshot 与 structured_state 同为 369 / 804；
整目标成功分别为 6 / 144 与 23 / 144。

整目标指标揭示错误分布；这里不能称为“两次重复均成功”。

总分变化，需要回到问题状态构成解释

六风暴 Qwen 的两个完整 system 条件；每行均使用相同计划分母。

参考状态	任意空白	默认空白	正确数变化
numeric	485 / 1,794 27.03%	502 / 1,794 27.98%	+17
not_stated	502 / 588 85.37%	545 / 588 92.69%	+43
DISSIPATED	13 / 30 43.33%	13 / 30 43.33%	0

总分 41.46% → 43.95%，多出的 60 个正确中，43 个来自 not_stated。

报告总分，同时报告 numeric、缺陈述状态、终止状态与风暴分组。

第二个模型揭示了输出协议的适配问题

本地 DeepSeek-R1-Distill-Qwen-7B；各条件固定计划 2,412，未收齐。

角色／空白	返回	结构合法	严格正确	length 结束
system／任意	1,604	1,514	3	90
system／默认	1,994	1,943	9	51
user／默认	2,064	2,011	6	53

严格正确的 3、9、6 份回答全部属于 not_stated；numeric 和终止组均为 0。
单位、目标、数值、引用与长度问题并存；本轮没有归一化或答案修补。

默认 JSON 分隔空白减少异常空白，但没有保证历史长度有界。

一条历史轨迹超限，会停止整个 worker

DeepSeek 六风暴条件：旧收集器使一条历史轨迹的失败牵连到其他方法。

实际下一批次：1 条超限 + 3 条可容纳

history：超过上下文上限

其他请求 1：当前可容纳

其他请求 2：当前可容纳

其他请求 3：当前可容纳

————→ worker
整体退出

角色／空白	最先超限轨迹	其他轨迹
system／任意	5	803
system／默认	3	415
user／默认	2	346

右表为未尝试槽位归属；不假设更远的其他请求一定可容纳或会答对。
极长的引用整数仍能增长到数千位，单独限制空白不足以解决问题。

下一版应隔离失败轨迹，让其他轨迹继续；历史失败与分母保持冻结。

未收齐的角色对照，必须保留缺失与分母

Qwen user／默认空白：1,628 返回，780 未尝试，4 结果未知；启动更晚。

主结果：952 / 2,412

39.47%

返回子集：952 / 1,628 = 58.48%
不能直接与完整 system 条件的
1,060 / 2,412 = 43.95% 比较。

user 返回覆盖	返回／计划
numeric	1,053 / 1,794
not_stated	567 / 588
DISSIPATED	8 / 30

双方返回部分，user 多答对 68；system 独有的返回部分有 176 个正确。
全计划正确数差：+68 - 176 = -108。共同返回子集也不是无偏校正。

比较完整任务准确率时给足完成预算；比较固定资源时先统一预算口径。

当前结论回到任务、证据和持续可靠性

新增结果扩展了整体 benchmark 的论证，并明确了需要补足的证据。

任务定义

对象 + 绝对目标时间
可见来源 + 当前明确覆盖

受控诊断与官方原文互补
当前主要覆盖热带气旋
预报陈述的使用

已有实证

内容正确与来源正确可分离
单点表现与整段成功可分离

相同历史的表示仍可有差异
状态、协议与缺失影响总分

结论边界

八个原生开发风暴来源
两个共享 Qwen 来源的模型

尚缺独立 heldout 结论
不等时限妨碍角色比较
不据此建立通用方法排名

可支持的贡献：可执行、可复核，并能解释失败的动态证据测量框架。

下一步按已发现的问题依次补证据

先提高比较的可解释性，再扩展模型和独立评测；本包没有启动新实验。

01	逐轨迹故障隔离	超限与未知结果只停止对应轨迹；先做离线故障注入。
02	冻结共同公共协议	公开表示边界、提示与评分版本；错误但合法的答案仍可生成。
03	分层扩展真实资料	补生命周期、真实终止修订和时间依据；保留准入失败。
04	等完成预算开发比较	先明确准确率或固定资源问题，再加入独立模型与重复。
05	独立 heldout 验证	协议冻结后确定风暴分组统计与污染边界。

当前失败已经给出明确的工作优先级；单纯增加调用量不能消除这些混杂。

附录 A1：六风暴完整模型条件表

每行计划 2,412；三种方法各 804；一次重复；主分母始终保留未返回项。

模型／角色／空白	返回	合法	严格正确	主正确率	未试＋未知
Qwen system／任意	2,412	2,411	1,000	41.46%	0 + 0
Qwen system／默认	2,412	2,412	1,060	43.95%	0 + 0
Qwen user／默认	1,628	1,628	952	39.47%	780 + 4
DS system／任意	1,604	1,514	3	0.12%	808 + 0
DS system／默认	1,994	1,943	9	0.37%	418 + 0
DS user／默认	2,064	2,011	6	0.25%	348 + 0

默认空白指 JSON 默认分隔符格式；三种条件各自生成历史，不是完整因子设计。

附录 A2：完成状态分三层说明

快照 2026-09-09 02:44 UTC；全部引用的阶段验收已存在并通过。

层面	截至快照的状态	含义
模型收集	部分条件收齐；部分停止	失败和缺失保留在计划分母
阶段验收	P7—P14 相应验收 passed	包括未收齐运行的可重建前缀
全局归档／发布	本包未核验统一闭合	不据此声明最新 GitHub 已包含全部结果

P11 原清单漏绑 14 个分析／命令文件，另有 30 文件补充；原始模型得分不变。

本包是带证据入口的阅读附件；完整科学复查仍需原始研究归档与清单。

附录 A3：并入旧汇报时保持论文主线

旧版解释为什么测、怎样测；补充包更新已有证据、当前结论和下一步。

旧内容	合并动作
1—9：问题与设计	保留结构；更新原生模型结果待采集的过时状态
11—14：受控与原文	接入 S02—S07：原文结果、表示、事件与指标
15—18：进展与结论	用 S09—S12 更新：测量问题、结论与执行优先级

阶段编号放附录；任一百分比旁保留分母，未收齐条件保留缺失。

动机 → 任务设计 → 互补实证 → 比较边界 → 下一步需要的证据