

DisasterTrace

天气证据更新中的 LLM 可靠性评测

从运行结果出发，解释每一次迭代

P5 已完成

1,620 条真实回答
83.95% 完整正确

P6 运行中

2,160 槽位
配对重复实验

已完成真实评测，正进入可靠性验证

将“软件闭环”“已测能力”和“正在验证的问题”分别报告

已完成 · P5 1,620 条回答 三因素压力评测 全部契约合法 1,360 条完整正确	已发现 · P6 归因 230 处纯引用错误 其中 109 处为同值旧版本 值正确仍可能引用失效	正在运行 · P6 2,160 个机会 base / scope × 2 repeats 统一完整 H100 配对执行
--	---	--

独立气象来源仍为 3 个风暴；生成变体、方法与重复不增加事件数。

核心任务：每次证据更新后，给出当前有据状态

四个字段、当前版本引用、一个明确的研究动作

任务族	关键变化	要检查的行为
U1 局部更新	只 PATCH 部分字段	更新目标；保留其余；刷新引用
U2 同窗口修订	修订 / 其他窗口 / 旧版重放	区分事实键；保持当前版本
U3 支持恢复	目标证据暂缺，之后交付	unknown → known；有据才回答

3 来源 × 3 任务族 × 2 case × 2 branch = 36 episode；每条 5 个 checkpoint

初始值来自真实 NHC；后续更新与交付是明确标注的受控构造。

三个方法共享累计证据，只改变额外答案载体

比较的是显式载体条件下的表现；所有方法仍能重新阅读原始证据

方法	公共证据	额外载体
snapshot	截至当前的累计记录	无历史答案
structured_state	同一累计记录	上一份结构合法的完整答案
answer_history	同一累计记录	此前全部结构合法答案

合法但错误的答案原样传播；无效答案计失败，不能用 Gold 修复载体。

当前比较的是显式答案载体，不直接识别模型内部长期记忆。

无需逐题人工判分：用可执行语义建立评分链

自动 Gold + 公开文本独立求解 + 严格评分 + 原始记录重算

受控事件 私有编译器 得到逐检查点 Gold	公开文本 独立 public oracle 验证输入可推出答案	真实回答 严格 scorer 值 / 状态 / 引用 / 动作	原始记录 独立 auditor CPU 重算与身份核对
---	--	--	--

known：正确数值 + 当前版本来源；unknown：null + 空引用；失败保留原分母。

不新增逐题人工标注，不使用 LLM judge；仍需检查共同语义假设。

迭代不是单调刷分：每轮回答一个新问题

输出交付 → 输出契约 → 格式与语义分离 → 压力诊断 → 配对可靠性

P1 → T6

输出交付失败

校准公共说明与 token 上限

P2 v1 → v2

契约仍有歧义

统一输出契约；270/270 全对

P3 → P4

平衡任务仍受格式干扰

独立建立结构约束轨

P5

合法后仍有语义错误

三因素压力；定位来源错误

P6 离线

分差解释有混杂

曝光审计、简单基线、错误归因

P6 实测

可靠性仍需重复验证

同硬件、配对种子、两次重复

新协议回答新问题；不同版本的分数不能画成模型能力单调上升曲线。

第一轮转折：先保证模型能交付可评分答案

P1 的失败推动 T6：明确公共格式，并统一选择 8,192 输出预算

P1：90 个回答，68 个合法；22 个失败中 20 个达到输出上限。

T6 条件	snapshot	structured_state	answer_history
原说明 / 4096	17/30	28/30	27/30
明确说明 / 4096	27/30	30/30	28/30
明确说明 / 8192	30/30	30/30	30/30

每条件 90 条，三条件共 270 条；8,192 是预定格式门槛下的共同选择。

第二轮转折：契约修订奏效，小矩阵出现天花板

P2 v1 与 v2 保留相同语义和评分机会；两轮都是真实新采集



条件	收到 / 计划	契约合法	完整正确
P2 v1	270 / 270	264 / 270	262 / 270
P2 v2	270 / 270	270 / 270	270 / 270

变化：共同输出说明明确 state / action / record_id / ASSERT 行引用。
结果：小型受控矩阵全对，下一轮需要平衡情形与扩展模型覆盖。

v1 的 6 个无效回答 + 3 处引用错误 → 8 个错误 checkpoint，不能直接相加。

第三轮转折：将格式交付与语义正确分开看

Qwen3-8B；同一平衡任务的自由输出 P3 与结构约束输出 P4



P4 全部格式合法，仍有 15 处值/状态错误 + 39 处引用错误。

P5：在 Gold 不变的前提下加入三类压力


每因素 36 episode × 5 checkpoint × 3 方法 = 540 条真实回答

01 / revision_chain 修订链 增加中间修订 30 个 episode 从 c2 暴露 6 个无新增压力保留	02 / irrelevant_scope 无关作用域 其他实体 / 有效窗口 36 个 episode 从 c2 暴露 目标 Gold 不变	03 / late_stale_replay 旧记录重放 旧记录更晚送达 36 个 episode 到 c4 暴露 旧版本不恢复权威性
---	--	--

三组各 540 条，共 1,620；保留完整 8,192 输出预算，不截断后混入结果。

P5 真实结果：全合法后，方法差异仍然存在


完整正确 checkpoint；每格固定分母 180，包含全部无效或缺失机会



P5 合计 1,360 / 1,620 = 83.95%；scope 下 snapshot 与结构状态只差 1 题。

主要可观察错误：值正确，来源却没有正确绑定

P5 的 320 处字段错误 = 90 处值/状态错误 + 230 处纯引用错误



109 / 230 = 47.39% 为同值旧版本；29 个动作错误与风速错误重叠。

真实例子：60 mph 没变，正确引用已经换了

P5 / irrelevant_scope / answer_history / Dorian 来源 / U1 secondary active / c2

实际模型回答

60 mph

record-62dacf3b... / line 2
已被替代的同值旧版本

当前正确依据

60 mph

record-0db797c9... / line 2
当前权威版本

数值评分：正确。当前版本来源评分：错误。

记录 ID 为展示缩写；完整 ID 和原始样例出处保留在详细文档中。

能力边界：当前合法任务可由简单公开策略完整求解

按完整事实键过滤后选择最新发布时间：base 和三组压力均为 180／180

公开程序策略	Base	Revision	Scope	Stale
initial_only	90	90	90	90
scope_blind_last_delivered	132	132	78	138
latest_issued_per_key	180	180	180	180
public_oracle	180	180	180	180

每格 /180。当前域限制为合法线性版本链；复杂图推理必要性尚未建立。

P6：把历史分差变成更有解释力的配对问题

两条件 × 两重复；统一模型、完整 H100 硬件与解码设置

2 conditions × 36 episode × 5 checkpoint × 3 methods × 2 repeats = 2,160

配对设计

base ↔ scope level 4

同硬件、同设置、条件间匹配 seed
条件顺序平衡；载体分别演化

可靠性指标

单次正确 → 全程稳定

保留双向变化与四种成对结局
episode success / pass² / 来源与重复范围

432 条运行轨迹，1,080 对条件机会；2 次重复不等于更多独立风暴。

最新执行状态：P6 正在收集真实回答

实时计数是运行进展；最终成绩仍需完整审计和报告验收

2026-09-08 12:52:04 UTC

1,680 / 2,160

77.8% 已保存

作业 pt-gxxtikov · 一张完整 H100 · 已安排自动审计与 CPU 后处理
离线正确/无效对照共 4,320 条程序回答，单独用于软件验证。

此页不报告 P6 临时能力分数；保存完成仍需最终作业状态与独立验收。

下一条数据主线：官方预报的真实多版本证据

先冻结和双解析小规模 NHC 原文，再建立独立的 forecast-claim 任务

已准备的来源范围 最多 12 份正文 Francine 005-010 Ida 009-014 双解析；不一致自动隔离	下一版核心查询 同一绝对有效时刻 哪份可见公告明确覆盖？ 预报值 / 单位是什么？ 当前依据在哪些原文行？	保持时间与任务边界 分开记录四种时间 issued / valid / retrieved 受控 delivery 另行记录 历史首次公开时间不编造
--	--	---

模型使用官方已发布预报；新的 forecast-claim 任务尚待离线构建与验收。

后续按可验收里程碑推进

先完成当前证据链，再增加真实数据、可解释对照与模型覆盖

顺序	交付物	完成门槛
1	P6 收尾	完整报告、双向配对、pass^2、CPU 迁移验收
2	原生预报轨	双解析准入 → 同绝对时刻任务 → 独立 Gold / scorer
3	载体表示对照	同一保存答案的 JSON / 文本；信息可逆、长度可测
4	同协议第二模型	先固定任务与预算，再做实际后端和硬件预检
5	扩展独立来源	扩大开发事件；冻结后再测全部受保护 heldout 范围

优先增加结论的可解释性与来源覆盖；新增模板数不等于新增独立事件。

当前成果与仍然缺少的证据

把研究局限转化为后续实验目标

已经支持	仍需验证
自动评分与可复查的真实采集闭环	真实原文的自动 Gold 语义与歧义处理
格式合法后仍有值和当前引用错误	配对重复后的稳定程度与来源差异
受控天气记录中的显式状态维护	真实预报、多事件、多模型外部有效性
不同答案载体下的描述性差异	等信息 / 等长度表示与内部记忆机制
定位：研究中的动态天气证据 benchmark；广域极端天气排行榜尚未建立。	

汇报应落在三个结论上

已建立评测闭环；已找到可复现错误；下一阶段有明确检验目标

- 01

已建立评测闭环

自动 Gold、真实采集、固定分母与离线重算。
- 02

已找到明确失败模式

P5 全部契约合法，仍有 90 处值错与 230 处引用错。
- 03

下一轮有可检验目标

配对可靠性 → 官方预报版本 → 同协议模型与来源扩展。

附录 A | 真实运行结果总表

所有数字均取自实际报告；不同版本和输出条件分别列示

阶段	模型	任务 / 条件	收到	合法	全对
P1	DeepSeek	公告轨 / 4,096	90	68	67
T6	DeepSeek	旧说明 4,096	90	72	68
T6	DeepSeek	明确说明 4,096	90	85	82
T6	DeepSeek	明确说明 8,192	90	90	83
P2 v1	DeepSeek	受控任务 / 18 ep.	270	264	262
P2 v2	DeepSeek	受控任务 / 18 ep.	270	270	270
P3	Qwen3-8B	平衡 / 自由输出	540	200	193
P4	Qwen3-8B	平衡 / 结构约束	540	540	490
P5	Qwen3-8B	修订链	540	540	449
P5	Qwen3-8B	无关作用域	540	540	444
P5	Qwen3-8B	旧记录重放	540	540	467

P1 为 90 回答 / 91 尝试；P6 2,160 槽位正在运行，未纳入已完成表。

附录 B | 指标与错误怎样计数

主分数保留固定分母；字段错误、checkpoint 错误和动作错误不可混加

指标	严格含义
契约合法	原任务结构与数值契约通过；仍可能内容错误
完整正确 checkpoint	四字段状态、值、当前引用与动作全部正确
episode success	单次 episode 的 5 个 checkpoint 全部正确
pass^2 (R=2)	同一条件 / 方法 / episode 的两次运行都全程成功
错误守恒	90 + 230 = 320 字段错误；落在 260 个错误 checkpoint
c0 的 324/324 全对单独披露；c1-c4 的 1,036/1,296 不替换主分母。	

附录 C | 完成证据与可复查交付

哈希、测试和离线重建支持可追溯性；不替代科学有效性论证

材料	已记录的完成证据
P5 实际运行	3 个 ACP 作业成功；9 个 collect / report / verify 子进程退出 0
P5 输出约束	432,742 个 final/EOS token 重放，无 grammar 违规
P4/P5 CPU 迁移	屏蔽原资料、权重与网络；无需 Torch / vLLM 重建报告
P6 离线程序验收	正确 2,160；无效对照 1,728 全对 + 432 无效保留
GitHub 已发布 P5	私有 next-phase-v1；dd5ee358f970；P6 本地记录更新

测试执行含重叠，不累加成独立测试或模型样本；未声称 GitHub Actions 已运行。

附录 D | 已有 benchmark 的设计参考

参考思想与已执行复现分开记录；本轮外部项目登记为 design_only

参考	采纳的设计方向
ALCE	将数值正确与引用支持分开测量
CheckList	最小功能、不变量与方向性测试；纯程序性质验证
tau-bench	整条 episode 成功率与多次运行 pass^k
RULER / MemoryAgentBench	区分长度、信息预算与增量观察协议
STATE-Bench / STALE	显式状态、来源版本与历史载体的边界
ExtremeWeatherBench / NHC	独立天气事件；预报目标与观测、来源时间分开
本轮为提供方案中的设计参考；不等同于下载、运行或复现全部上游 benchmark。	