

DisasterTrace

详细进展说明

从零理解任务原理、已有结果与下一步

覆盖已验收的 P6 真实模型评测，以及 P7 官方预报原生任务离线验收。适合先通读理解，再精简为研究汇报。

P6：真实模型结果	2,160 条回答 1,861 条完整正确 · 86.2%
P7：原生任务离线验收	46 个目标 · 257 个查询 模型调用为 0
下一步	原生采集与四 worker 聚合 预检后冻结首次 1,542 机会实测

本文包含教学示例、真实错误记录、统计单位解释、阶段结果、官方原文案例及实施路线。教学例与真实模型/官方来源案例分别标明。

目录

目录列出 17 个章节；PDF 书签进一步列出各节，可直接定位术语、结果和实施计划。

1. 项目究竟想解决什么问题	3
2. 先把几个容易混淆的单位讲清楚	4
3. 一次完整评测怎样运行	5
4. 用一个教学样例理解 P6	6
5. 三种方法比较的究竟是什么	7
6. 从早期试跑到 P6，具体完成了哪些阶段	8
7. 最新 P6 实验的规模与结果怎样理解	9
8. 模型具体错在哪里：从统计到真实例子	11
9. 配对比较说明了什么，又没有说明什么	13
10. 从受控任务推进到官方预报原文	14
11. P7 新增了什么：从资料变成完整原生任务	15
12. P7 的程序成绩怎样读，为什么还不是模型成绩	17
13. 为什么有 FAILED，却仍说 P6 已完成	19
14. 目前到底完成了什么，还没完成什么	20
15. 下一步怎样推进，每一步解决什么	21
16. 怎样判断研究贡献，以及怎样交给 ChatGPT 精简	22
17. 证据入口与阅读材料	23

这份文档帮助你从头理解项目：我们想测什么、具体怎样测、各阶段做了什么、已有结果说明什么，以及下一步还缺什么。它可以作为后续让 ChatGPT 精简汇报的完整底稿。

内容截止于已验收的 **P6 真实模型评测与 P7 原生预报任务离线验收**。对应证据于 2026-09-08 核对。本说明不将进行中的后台任务计数混入这些已完成结果。

最重要的三个状态先放在这里：

- **P6 已获得真实模型结果**：Qwen3-8B 完成 2,160 条回答，1,861 条完整正确，约 86.2%。
- **P7 已完成原生任务的软件准备与验收**：使用官方 NHC 预报原文建立 46 个目标、257 个查询，并完成独立求解、评分及程序对照。
- **P7 还没有模型成绩**：1,542 是待模型作答的计划机会数；程序生成的诊断答案不是 LLM 的回答。

建议先读第 1–5 章理解任务，再读第 6–9 章理解 P6 结果，第 10–12 章理解新增 P7，最后读第 13–16 章理解工程状态、限制和后续路线。

1. 项目究竟想解决什么问题

1.1 最初的目标与当前落点

你的总体目标是建立一个与极端天气有关、用于评测大语言模型的 benchmark。Benchmark 在这里可以理解为一套固定的考试体系：题目怎么来，模型能看哪些材料，要交什么答案，怎样判分，以及不同模型怎样公平比较，都要事先说明。

“极端天气 benchmark”本身仍然很宽。它可以测试气象知识问答、预报解读、风险沟通、数值预测、工具使用或应急决策。当前 DisasterTrace 选择的具体落点，是**天气证据不断更新时，LLM 使用证据和维护状态的可靠性**。

这里的“状态”就是模型当前认为目标对象有哪些属性，以及每项属性由哪条证据支持。例如，对于一个指定风暴、指定有效时段，当前支持的风速是多少，气压是多少，位置在哪里；如果支持材料还没出现，哪些字段应当暂时保持未知。

模型不是凭常识猜答案。实验会把相关资料交给模型，再观察它能否按公开规则使用这些资料。后续材料可能只更新其中一部分，也可能属于其他对象或时间；旧资料还可能在新资料之后重新出现。

1.2 为什么不能只问一次、对一下数字

假设旧记录给出的风速是 100 mph，新记录也给出 100 mph，但明确替代了旧记录。模型继续回答 100，数值没有错。然而，如果它仍引用旧记录，就不能说明它正确追踪了当前证据版本。

再假设一份更新的记录给出 120 mph，却属于另一个风暴或另一个有效时段。模型如果只采用“最新”“最大”或“最后看到”的数字，也可能出错。

所以当前研究希望把三个问题分开测量：**内容是否正确、来源是否正确、这种正确性能否持续保持**。多个检查点和重复运行，就是为了把第三个问题也纳入评测。

1.3 当前尚未评测的能力

当前没有要求 LLM 独立预测真实未来天气，再与实际观测比较误差。P7 使用“预报”这个词，是因为输入材料是官方已经发布的预报；模型要正确读取和更新其中的陈述。

目前也没有证明模型能够做好真实撤离、港口停运或救灾资源分配。P6 的动作字段是由公开阈值唯一决定的研究规则。它方便检查状态与下游输出是否一致，不能替代业务决策验证。

当前自然来源主要是 NHC 热带气旋资料。项目的长期名称可以面向极端天气，但现有证据还不能代表暴雨、热浪、暴雪、洪水等全部灾种。

2. 先把几个容易混淆的单位讲清楚

2.1 从一份资料到一条回答

术语	在本项目里的具体含义
来源风暴	一个独立天气事件，例如 Ida 或 Francine；同一风暴的多份公告不算多个独立风暴
产品或公告	官方在某个时刻发布的一份资料；一个风暴会有多个版本
目标事实键	需要回答的是哪个实体、哪个时间、哪个变量、哪种测量及单位
episode	围绕同一个目标组织的一段更新任务，可以包含多个检查点
检查点 checkpoint	资料交付过程中的一个提问时刻；模型在这里提交一次答案
方法 method	如何把先前模型答案附加到当前输入，例如只附上一轮状态或全部历史
重复 repeat	在冻结设置下重新运行同一任务的一次身份；不等于出错后补考替换
轨迹 trajectory	一个 episode 在一个方法、一个条件、一次重复下实际走过的完整过程
回答机会 slot	计划中本来应该有一次回答的位置；即使无效或没有返回，也保留这个位置

P6 中，一条基础 episode 有五个检查点。三个方法、两个条件、两次重复，会让同一基础 episode 产生 12 条轨迹，每条轨迹五次回答。

因此 P6 的 36 条基础 episode 对应 432 条轨迹、2,160 个回答机会。它们仍然来自三个独立风暴来源，而不是 2,160 个独立天气事件。

2.2 Gold、公开求解器和 scorer 各是什么

Gold 是根据任务规则计算出的参考答案。对于某个检查点，它记录正确状态、数值以及应引用的当前来源。Gold 保存在评测侧，不放进模型请求，也不用于修正模型历史。

公开求解器是一段只读取模型可见材料的独立程序。它按同样公开规则求解，检查模型是否有足够的信息得到答案。它不能读取隐藏 Gold 来“答题”。其实现与参考答案编译器分开，以减少两边共享同一个实现错误的风险。

scorer 是评分程序。它比较提交答案与任务规则，分别检查结构、目标、状态、值、单位、当前来源和定位等要求。确定性评分意味着：同一份输入和答案在同一版本规则下应得到相同结果。

这三者的职责不同。Gold 给出参考，公开求解器检查公开可解性，scorer 判定实际提交。程序对账一致可以增强可信度，但仍不能排除共同误解了任务语义，因此规则和限制也需要公开。

3. 一次完整评测怎样运行

3.1 先建立题目，再调用模型

完整流程可以按下面的顺序理解：

1. 保存来源原文、版本信息、文件哈希和可定位的行号。
2. 声明任务目标、时间语义、来源选择规则和允许的答案格式。
3. 生成 episode 与证据交付安排，确定每个检查点能看到哪些材料。
4. 在评测侧生成 Gold，并用独立公开求解器对账。
5. 冻结方法、模型、输入预算、输出轨道、调度和机会数量。
6. 逐检查点调用模型，先保存原始回答，再解析与评分。
7. 按该方法的规则把模型自己的答案带入后续检查点，保留原有错误。
8. 汇总分数与失败模式，并在独立环境中重建结果。

“冻结”是为了防止看到结果后再调整题目、挑选容易成功的样本、修改评分规则或替换不满意的回答。未来如果发现通用实现缺陷，应另立版本并保留原始结果，不能静默覆盖。

3.2 模型究竟看到了什么

模型能看到公开任务说明、当前目标、当前检查点的信息，以及截至当前已交付的证据。根据方法不同，还可能看到自己先前生成的答案。

模型看不到尚未交付的证据正文、隐藏参考答案、正确来源标签、评分结果或为了让它答对而修复过的历史。研究者事后看 Gold 分析错误，与把 Gold 提供给模型，是两件不同的事。

每个检查点都是新的请求。所谓多轮状态，不依赖服务端悄悄记住整段聊天，而是由实验明确规定传入哪种历史载体。这样才能知道模型在这一轮实际获得了哪些信息。

3.3 为什么必须保留无效和缺失回答

假设计划有 100 道题，模型只在 80 道上返回可用答案。如果只在这 80 道上计算正确率，会掩盖交付失败。当前协议把所有计划机会留在分母中，缺失、无效和某些基础设施失败都不能通过悄悄减少分母消失。

当前 P6 恰好收齐了全部 2,160 个答案。P7 的无效与缺失程序对照，则是主动检查未来遇到这类情况时，评分和聚合是否仍然保留机会数。

4. 用一个教学样例理解 P6

以下是解释规则的教学示例，不是实际模型回答，也不是新增 benchmark 样本。只展示风速这一字段；真实 P6 要联合提交四字段与动作。

假定目标一直是同一个实体、同一个有效窗口。R1、R2、R3 都在材料中明确说明它们属于该目标，并声明修订关系。

检查点	新交付材料	正确的风速状态	当前引用应是什么
c0	尚无支持风速的材料	unknown，值为 null	空引用
c1	R1：风速 100 mph	known，100	R1 的支持行
c2	R2 替代 R1：110 mph	known，110	R2 的支持行
c3	R3 替代 R2：仍为 110 mph	known，110	更新到 R3 的支持行
c4	另一目标的 160 mph；旧 R1 重新出现	保留 known，110	继续使用 R3

这个例子里有四种不同能力。c0 检查缺证时能否承认未知；c2 检查数值更新；c3 检查同值时的来源刷新；c4 检查目标作用域与旧版重放。

如果某次修订只更新风速，未提及的气压、纬度和经度不应被清空。P6 的局部更新语义明确要求保留其他字段；遗漏某字段不是撤销它的事实。

4.1 正确输出不只是一句自然语言

下面是 c3 的风速字段节选，省略了其他字段和动作，因此不是完整合法的最终答案：

```
{
  "maximum_wind_mph": {
    "status": "known",
    "value": 110,
    "evidence": [{"record_id": "R3", "line": 2}]
  }
}
```

评分可以分别发现：把 110 写成 100，是值错误；写成未知，是状态错误；值写对却引用 R2，是当前来源错误；引用一个不存在的行号，是定位错误。

4.2 三个任务族怎样对应这些行为

P6 任务族	主要控制的变化	检查的行为
U1 局部更新	部分字段更新，也包括数值不变但来源更新	更新该更新的字段，保留其他字段，刷新当前引用
U2 同窗口修订	同键修订、其他实体或窗口的记录、旧记录再交付	识别正确事实键与当前版本，不被其他作用域带偏
U3 支持恢复	某字段支持暂未交付，之后交付	正确表达 unknown，并在有证据时恢复 known

基础平衡设计是三个来源、三个任务族、两个 case、两个 branch，共 36 条基础 episode。它让不同来源覆盖同样的任务类型。case 和 branch 是受控任务的设计变体，不是新的天气事件。

4.3 为什么材料中有人工构造的时间和实体

P6 的初始值借助真实 NHC 来源，但后续实体、有效窗口、修订与交付是明确标记的 `controlled_generated` 内容。它们用于建立可精确判分的实验。

因此某些记录中出现 2040 年等时间，是受控实验时间轴，不代表正在预测 2040 年的真实天气，也不代表官方发布了这些修订。汇报时需要把真实来源初值与受控后续变化区分开。

5. 三种方法比较的究竟是什么

5.1 所有方法都能重新读取累计原始证据

方法	本说明中的简称	截至当前累计已交付证据	P6 中额外附加的模型信息
snapshot	仅证据	都能看到	不附加历史答案
structured_state	上轮状态	都能看到	上一份结构合法的完整模型答案
answer_history	全部历史	都能看到	此前全部结构合法的模型答案

这里特别容易误解的是 snapshot。它不是只看最新公告，也不是失去旧资料后凭记忆回答。它仍然可以重新读取截至当前已交付的累计证据，只是不额外看到自己之前怎么答。

structured_state 提供一个紧凑的上轮答案载体。answer_history 提供更长的答案历史。若先前答案结构合法但数值或引用错误，这个错误会原样传递，不会用 Gold 修正。

5.2 更多历史为什么未必更好

更多历史可能帮助模型保持状态，也可能让它继续依赖旧结论或错误引用。输入还会变长，重复的模型陈述可能与权威原文竞争注意力。这些都是值得检验的可能解释，而不是由当前分数直接证明的内部机制。

因此当前比较的是三种完整输入配置的实际表现。它同时改变历史数量、表示形式、token 长度和错误携带方式。观察到 structured_state 分数较高，不能单独归因于“结构化记忆更优”。

下一阶段的等信息载体控制，就是把同一份保存的模型状态分别渲染为 JSON 和文本，保留完全相同的值、状态、引用和已有错误，再测量表示与长度差异。信息相同也不意味着 token 数相同，这两件事要分别核验。

5.3 P7 的同名方法有独立契约

P7 仍使用这三个方法名称，但历史处理按原生任务另行冻结：structured_state 携带上一答案或显式无效/缺失标记；answer_history 保留此前自己的原始最终文本与缺失标记。

所以代码不能只看方法名字相同，就把 P6 的载体处理、五轮假设和动作结构直接搬过去。两阶段的成绩和运行契约需要分开解释。

6. 从早期试跑到 P6，具体完成了哪些阶段

6.1 为什么先花时间解决格式与交付

一个模型可能推理了很久，却因为输出上限耗尽，没有留下完整答案；也可能输出带代码围栏的 JSON 或额外解释，违反预先声明的解析规则。此时低分混合了交付、格式和内容错误，不容易解释为状态更新能力差。

早期 DeepSeek 阶段因此先进行输出契约和预算校准。这里的 token 可以近似理解为模型处理与生成文本的计量单位，不等同于中文字符。启用推理时，预算还需要为推理和最终答案共同留出空间。

6.2 各阶段的完成情况

阶段	做了什么	实际结果	推动了什么下一步
P1	首轮三方法 DeepSeek 开发试验	90 个收到的 benchmark 回答；68 个合法，67 个全对	发现输出上限和格式交付是主要瓶颈
T6 校准	对照原说明/4096、明确说明/4096、明确说明/8192	270 个新回答；8192 条件 90/90 合法、83/90 全对	选择更充分的共同输出预算，并区分格式与内容
P2 v1	受控任务的首轮开发比较	270 回答，264 合法、262 全对	进一步明确共同输出契约
P2 v2	新契约下重新采集	270/270 合法且全对	小矩阵区分度不足，需要扩展平衡任务
P3	36 episode 的 Qwen3-8B 自由输出评测	540 回答，200 合法、193 全对	需把输出形式问题与语义诊断分轨处理
P4	独立的结构约束输出轨	540/540 合法，490 全对	形式可靠后，仍有状态和来源错误
P5	三种 level 4 压力条件	1,620 回答，全部合法，1,360 全对	需要进一步控制比较条件并做重复实验
P6	基础/无关作用域配对，两个重复	2,160 回答，全部合法，1,861 全对	获得可解释的来源错误与轨迹可靠性结果

P1 的 90 个回答跨 91 次物理尝试，历史中断与单次补发另有记录；不能把尝试数和已收到答案数混用。T6 的 270 包含三个条件，不能只拿其中 90 个格式全过的子条件代表全部校准结果。

这张表展示的是研究过程。模型、任务范围、提示词、输出轨道、种子、硬件或运行时间不同，因此不能把行与行之间的分数差都归因于单一改动，也不能画成模型经过训练后能力提升的曲线。本项目这些阶段没有训练模型。

6.3 结构约束到底做了什么

P4 之后采用单独的 structure-only 输出轨，用语法约束提高答案符合结构契约的可靠性。它约束容器、字段、类型等形式，不把正确数值、正确来源 ID、正确行号或正确动作给模型。

结构合法只说明答案符合规定的外形，不说明内容正确。P4 的 540 条答案全部合法，但仍只有 490 条完整正确，就是一个直接例子。

结构约束会改变解码分布，也会影响模型后续历史，因此它不是把 P3 的旧回答“修一修”后得到的新分数。自由输出与结构约束是分别运行和报告的轨道。

6.4 P5 与 P6 不能混在一起说

P5 做了 revision_chain、irrelevant_scope、late_stale_replay 三种压力因素。P6 当前完成的配对实验只比较 **base** 与 **irrelevant_scope level 4**。

P6 的 base 是基础受控任务，不等于完全没有更新或作用域辨别。干扰条件是在这个基础上增加冻结的 level 4 无关作用域压力，目标 Gold 不变。

P6 采用同一完整 H100、同一固定 Qwen3-8B、同一输出轨道，并在对应条件间共享采样种子。这样增强了条件比较的可解释性，但不自动解决所有统计或机制问题。

7. 最新 P6 实验的规模与结果怎样理解

7.1 2,160 是怎样得到的

2 个条件 × 36 条基础 episode × 5 个检查点 × 3 种方法 × 2 次重复
= 2,160 个回答机会

2 个条件 × 36 条基础 episode × 3 种方法 × 2 次重复
= 432 条运行轨迹

36 条基础 episode × 5 个检查点 × 3 种方法 × 2 次重复
= 1,080 对条件配对的检查点

对应条件共享种子，但方法与重复仍进入种子标识；不同方法和不同重复不是全部使用一个无差别种子。载体按轨迹隔离，没有把一种方法的答案交给另一种方法。

模型设置为固定 Qwen3-8B、BF16、一张完整 H100、TP=1，启用 thinking，输出上限 8192，上下文 16384，结构约束为 XGrammar。当前整个矩阵实际由单卡完成。

所有 2,160 条回答已收到且结构合法，36/36 格式屏通过；没有通过重试、替换或 Gold 修补消除失败答案。完整正确为 1,861/2,160，即 86.2%。

7.2 “完整正确”比“数字大致对”严格在哪里

P6 一条答案要同时满足四字段的状态、数值和当前来源引用，以及研究动作。任何一个必要部分错了，这个检查点就不是完整正确。

当前动作规则为：已知风速至少 100 mph 时输出 prepare，低于 100 时 monitor，未知时 request_evidence。这是公开、确定性的研究规则，不是对真实应急建议质量的人工判断。


因此总体 86.2% 是当前受控任务的联合指标，不是模型的天气预测准确率，也不是仅风速数值的准确率。

7.3 完整结果表

条件	方法	R0 全对 /180	R1 全对 /180	合计全对 /360	五轮全对 /72	两次均五轮全对 /36
基础	仅证据	171	169	340, 94.4%	55, 76.4%	22, 61.1%
基础	上轮状态	171	178	349, 96.9%	64, 88.9%	30, 83.3%
基础	全部历史	144	135	279, 77.5%	37, 51.4%	13, 36.1%
干扰	仅证据	152	157	309, 85.8%	31, 43.1%	11, 30.6%
干扰	上轮状态	157	162	319, 88.6%	43, 59.7%	15, 41.7%
干扰	全部历史	139	126	265, 73.6%	34, 47.2%	10, 27.8%


检查点完整正确率 (%)

每方法 / 每条件: 360 个检查点



两次均五轮全对 (%)

每方法 / 每条件: 36 条基础 episode



上轮状态：检查点 96.9% → 88.6%；两次均五轮全对 83.3% → 41.7%

图 1：不同指标回答不同问题。左侧分母为每方法每条件 360 次回答；右侧分母为 36 条基础 episode。颜色对应基础条件与无关作用域干扰。

7.4 三种成功率为什么不同

“检查点全对”问的是：任取本矩阵的一次回答，它是否全部正确。每方法每条件有 $36 \times 5 \times 2 = 360$ 次回答。

“五轮全对”问的是：一次完整运行能否五个检查点全部正确。每方法每条件有 $36 \times 2 = 72$ 条轨迹。一个检查点失败，就会使所在轨迹不能算五轮全对。

“两次均五轮全对”进一步要求同一条基础 episode 的两次运行都五轮全对。每方法每条件只有 36 个这样的判断单位。本项目把它记为 pass^2 。

pass^2 不是两次中至少一次成功的 $\text{pass}@2$ ，不是单点准确率的平方，也不是置信区间。因为错误在检查点、episode 和重复之间相关，不能把单次概率假设独立后相乘，替代这里的实测比例。

7.5 最值得在汇报中解释的结果

上轮状态方法加入干扰后，检查点全对率从 96.9% 降到 88.6%。只看后一个数字，可能会觉得系统仍相当可靠。

但同一方法的“两次均五轮全对”从 30/36 降到 15/36，即 83.3% 降到 41.7%。这揭示了不同评价粒度会影响对可靠性的判断：单次回答表现较高，不代表整段流程反复执行时都稳定。

这也是当前 benchmark 的一项实证价值：它能把短期回答正确与持续更新可靠分开呈现。现有结果仍局限于这个模型、这批来源和这套任务，不能直接宣布某种方法普遍最好。

8. 模型具体错在哪里：从统计到真实例子

8.1 先区分字段错误与回答错误

2,160 条回答各有四个字段，因此共有 8,640 个字段机会。字段归因发现 123 个值或状态错误，以及 259 个纯引用错误，合计 382 个字段错误。

完整错误的检查点是 $2,160 - 1,861 = 299$ 个。一条回答可能有多个错误字段，所以 382 不等于 299，也不能把它们相加。

另有 43 个动作错误，可能与字段错误重叠。例如风速错了，按该风速选择的动作也可能错。它不是可以直接加到 299 上的另一批独立失败。

字段主要错误类别	数量	直观含义
状态或数值不匹配	123	应有的数值或 known/unknown 状态不对
同值旧版本	116	数字正确，但引用的版本已被替代
不存在的记录 ID	42	引用没有对应的记录
错误有效窗口或测量种类	35	取了其他时间或其他类型的事实
行号越界	26	记录存在，但所指行不在范围内
错误实体	22	引用属于其他对象
错误变量或单位	10	来源支持的字段或单位与问题不符
异值旧版本	8	输出数值可正确，但附带引用的旧版本内容不同

“纯引用错误”表示值或状态已经正确，但引用规则没有满足。116 个同值旧版本占 259 个纯引用错误的 44.8%。只检查数值会遗漏这一类问题。




图 2：右侧细分的是 259 个纯引用错误；左侧的 123 个值或状态错误与它们分开统计。两者合计为 382 个字段错误。

8.2 一条来自实际模型的同值旧来源错误

以下记录来自已保存的 P6 字段归因，不是教学编造。按原文件顺序，选取第一条主要错误为 superseded_same_value 的记录，没有按哪个方法最差来挑选。

项目	实际记录
来源组与受控样本	AL052019，即 Dorian 来源组；U1、secondary、control 衍生 episode
实验条件	irrelevant_scope
方法与重复	answer_history，repeat 0
检查点与字段	c2，maximum_wind_mph
模型答案	known，60 mph
正确参考值	known，60 mph
模型引用	record-62dacf3b5260c5a4f615951f，第 2 行
当前应引用	record-0db797c9653dc4d169f593f5，第 2 行

审计记录显示：模型引用的记录确实存在，行号合法，事实键匹配，而且该行确实支持 60 mph。错误在于这份来源已经不是当前版本。它曾在更早检查点正确，而且引用与前序载体的引用相同。

因此这次失败不宜简单描述成“模型编了一个不存在的数字”或“引用全是假造”。更准确的描述是：**模型数值答对，也找到了字面支持，但没有完成来源版本刷新。**

“与前序载体相同”是观察到的关联，不能据此单独证明模型内部发生了哪一种记忆机制。要判断载体本身的因果影响，还需控制相同前缀和证据的表示实验。

这条受控记录使用 2040 年的实验有效窗口。它不是 Dorian 的实际未来预报，而是从该来源组生成的受控任务。完整记录保存在本报告配套的 evidence/p6_actual_error.json 中。

8.3 为什么要分开字面支持与当前版本

字面支持回答的是：“这条来源有没有写出模型所说的内容？”当前版本回答的是：“根据公开任务规则，现在应当由哪一版来源支持这个目标？”

在同值修订中，两个问题的答案可能不同。为了让读者判断任务要求是否合理，应分别报告数值、字面支持和版本正确性，而不是把它们全部折成一个无法解释的总分。

P7 已把这种区分进一步写入原生评分规则：可以检查旧公告是否字面支持指定目标的值，也单独检查它是否满足任务内的当前来源选择规则。

9. 配对比较说明了什么，又没有说明什么

9.1 为什么共享种子还要核对输入输出

P6 的对应条件共享采样种子，是为了减少不必要的随机差异。但相同种子本身并不保证所有硬件、调度和后端下逐比特一致，所以还需要实际检查。

额外无关作用域压力从 c2 开始出现。c0 和 c1 尚未暴露于这个新增因素，因此它们是重要的前置对照。实际核对发现，c0、c1 各有 216 对，共 432 对，请求与最终文本全部一致，两边都完整正确。

这使“差异在新增干扰出现后才发生”的描述有了证据。它不意味着后面所有差异都来自单个孤立机制。

9.2 曝光后的四类结果全部保留

每种方法在 c2–c4 有 216 对检查点。每对可以是两边都对、仅基础条件对、仅干扰条件对，或者两边都错。

方法	两边都对	仅基础对	仅干扰对	两边都错
仅证据	151	45	14	6
上轮状态	168	37	7	4
全部历史	97	38	24	57

三种方法都是“仅基础对”多于“仅干扰对”，但反方向的改善确实存在。完整保留这四类，才能看到净变化由哪些配对组成。

只计算曝光后部分，基础与干扰条件的全对数分别是：仅证据 196/216 与 165/216，上轮状态 205/216 与 175/216，全部历史 135/216 与 121/216。这是补充切片，不替代完整预定矩阵的主分母。

全部历史的净下降较小，不足以称它最抗干扰：它在基础条件下已经较低，两边都错的配对也更多。比较鲁棒性需要同时看起点、终点和错误分布。

9.3 为什么暂时不能做普遍的机制结论

在 c2，两条件可能产生不同答案；到 c3，先前不同答案又可能进入载体。因此后续差异混合了当前新增材料和之前输出的影响。这叫闭环轨迹比较，意思是模型自己的输出会进入后续输入。

若要只研究 JSON 与文本表示的直接影响，需要从同一个保存前缀开始、看到同一份当前证据，只改变载体的表示形式。这个固定前缀诊断回答的问题与自主运行整段 episode 不同，不能混在同一可靠性表里。

统计上，当前只有三个独立风暴来源、两个重复。不能把 2,160 次相关回答当成 2,160 个独立天气事件，计算出很窄的置信区间后宣称对所有极端天气显著成立。

10. 从受控任务推进到官方预报原文

10.1 为什么需要新增这条研究线

P6 的优点是语义明确、错误可控、Gold 可以精确计算。它的限制也清楚：后续更新由研究程序构造，不能直接证明模型在自然形成的官方预报文本中会出现同样的问题。

因此下一步不是单纯增加受控模板数量，而是检查真实官方资料中是否存在可严格对齐、可追溯的版本变化，并将其变成独立任务。

来源试点选择 Francine 的 005-010 号和 Ida 的 009-014 号 NHC 预报公告，共 12 份。全部收到并通过两个独立实现的解析器对账，0 份隔离。保存了原始内容、来源地址、哈希、获取信息、规范文本及原始字节/行映射。

这些产品提供 95 行预报，其中 9 行为终止状态；同一绝对有效时刻的相邻覆盖版本形成 49 对，其中 23 对持续风速变化、24 对风速不变、2 对涉及终止状态。

两个解析器读取同一份官方产品，作用是交叉核验实现，不是两个独立气象观测源。12 份产品也只来自两个风暴，Ida 还与旧开发来源重叠。

10.2 一个真实 Francine 修订例子

固定目标：Francine 在 **2024-09-10 18:00 UTC** 的最大持续风速。

公告	发布时间 UTC	对该目标时刻的明确内容
005	2024-09-09 21:00	75 KT；位置 25.9N、95.9W
006	2024-09-10 03:00	没有该目标时刻的明确预报行，包含其他有效时刻
007	2024-09-10 09:00	70 KT；位置 25.4N、95.6W

对应原文节选：

Advisory 005
FORECAST VALID 10/1800Z 25.9N 95.9W
MAX WIND 75 KT...GUSTS 90 KT.

Advisory 007
FORECAST VALID 10/1800Z 25.4N 95.6W
MAX WIND 70 KT...GUSTS 85 KT.

注意 MAX WIND 是最大持续风速，GUSTS 是阵风，不能因为后面的数字更大就替换前者。经度 W 在任务的有符号数值里表示负数。

第 005 号中，目标时间相对其中心参考时刻为 21 小时；第 007 号中为 9 小时。同一绝对有效时刻可以对应不同相对时效。如果拿两份公告里“同样相对时效”的行来比较，就可能对错日期。

10.3 第 006 号没有目标行时，任务为什么保留旧明确行

P7 明确声明：在已交付、可见的产品中，选择最新且明确覆盖同一目标有效时刻的预报。较新产品没有这一行时，不通过插值创造一个来源没写出的值，也不自动删除先前明确陈述。

这是一个任务内的已发布陈述解析规则。它**不证明**旧公告的该时效在真实气象业务中始终被认为“当前有效”，也不代表 NHC 将所有旧预报都判为错误。这是研究需要持续讨论的任务效度边界。

换句话说，当前要测的是“按明确规则找出可见资料中的目标预报陈述”，而非重建完整业务系统的预报生效政策。

10.4 五个时间概念需要分开

时间	含义	当前能否确定
issued_at	产品所标注的发布时间	可从产品解析
center_at	文本中明确的风暴中心参考时刻	可从产品解析，不等同于数值模式初始化
valid_at	某一预报行所针对的未来时刻	可从预报行解析并补全日期
retrieved_at	本次归档内容被获取的时间	本次采集记录可确定
available_at	历史上首次能公开取得该产品的时刻	尚未证明，保持未知

P7 用发行顺序安排受控交付，并用当前交付产品的发行时刻定义未来查询截止线。这不证明当年的网络到达顺序，也不把归档获取时间当成历史可用时间。数值模式初始化时间同样保持未知。

11. P7 新增了什么：从资料变成完整原生任务

11.1 当前已经完成的不只是下载和解析

P7 实现了原生任务规范、数据编译器、独立公开求解器、评分器、调度、上下文检查、程序对照和可迁移 CPU 验证。它读取已保存的 12 份官方公告，没有新增下载，也没有触及 heldout。

参考编译器从原始字节重建双解析入库结果与支持位置。独立公开求解器使用自己的文本解析实现，只读取模型将看到的完整带行号公告。scorer 单独检查目标时间、状态、单位、数值、版本、字面支持和定位。

所以相比 P6 后的来源试点，P7 已经从“有了资料”推进到“有了一套可以运行并自动验证的原生任务”。但此阶段的执行对象是程序对照，尚不是 LLM。

11.2 46、276、257 和 1,542 分别是什么

先对每个风暴取全部已入库预报行的绝对有效时刻并集。每一个“风暴 + 有效时刻”是一个目标，共得到 46 个目标。

每个风暴有六份选定公告，也就是六个交付检查点。46 个目标与各自六次交付组合，得到 276 个候选查询。然后严格排除目标时刻已经不早于当前参考时刻的 19 个非未来查询，最终保留 257 个。

计数	数量	怎样得到
独立风暴	2	Francine 与 Ida
公告产品	12	每风暴六份
来源预报行	95	各公告中的明确预报行，含终止行
目标 episode	46	不同风暴与绝对有效时刻的组合
候选查询	276	46 个目标各与六次交付组合
非未来排除	19	不满足严格未来条件
纳入查询	257	$276 - 19$
每策略计划回答机会	1,542	$257 \times \text{三方法} \times \text{两重复身份}$
方法/重复轨迹	276	$46 \times \text{三方法} \times \text{两重复身份}$

候选查询与方法/重复轨迹恰好都为 276，但它们是两个不同的计数，不能互相替代。

每条目标 episode 的有效检查点数量不同：长度为 2、3、4、5、6 的 episode 数量分别为 2、2、2、1、39。它们的加权和是 257。因此原生运行器必须支持可变长度，不能继续假设每条都五轮。

11.3 三种查询状态如何形成

257 个纳入查询中，有 176 个 numeric、26 个明确终止状态、55 个 not_stated。

numeric 表示可见公告中存在该目标的数值预报。终止状态例如 DISSIPATED，要明确输出终止状态和 null 数值，并引用终止行；不能把它变成零风速。not_stated 表示当前可见资料尚无该目标的明确预报行，输出空数值与无引用。

目标目录来自整批声明的来源，因此一个被提问的目标时刻可能尚未在当前交付资料中出现。这是公开声明的查询设计，不是在模拟实验者事先不知道会出现哪些日期的惊喜查询。未来公告正文、答案及来源身份不会因此进入模型请求。

11.4 257 个检查点上发生了哪些变化

变化标签	数量	含义
首个检查点	46	每个目标 episode 的起点
仍未陈述	25	仍然没有可见的明确目标行
首次明确预报	30	目标预报第一次进入可见材料
新公告未覆盖目标	107	依任务规则保留先前明确行
覆盖版本间风速变化	23	同目标持续风速发生变化
覆盖版本间风速不变	24	风速相同，但仍要跟踪版本
涉及终止状态的修订	2	需要处理明确终止语义

这七类合计 257。24 个风速不变修订不代表坐标和限定语也完全不变。107 个覆盖缺口来自自然公告网格差异，并非为了制造困难而伪造的修订。

11.5 输出与 P6 有什么不同

P7 联合回答纬度、经度与最大持续风速。纬经度单位为 deg，北和东为正；风速单位为 KT。答案还必须包含 storm_id、绝对 valid_at、measurement_kind、状态和支持行定位。

原生任务不要求未来气压，不从当前观测气压推算未来风速，也没有 P6 的研究动作字段。原始公告中的阵风、观测、半径和限定语仍保留为完整可见上下文，但 v1 不把它们全部设为必答字段。

12. P7 的程序成绩怎样读，为什么还不是模型成绩

12.1 程序对照是给测量工具做检查

在投入模型采集之前，需要知道题目确实公开可解，评分能抓住想测的错误，缺失和无效回答会正确留在分母里。为此使用一个合法公开求解器和八个错误或异常策略。

程序不是通过 API 请求某个 LLM 生成的答案。它们按事先写好的规则从公开输入生成结果。三种方法和两个重复身份在这里主要验证调度、载体和核算逻辑，不提供随机模型可靠性证据。

12.2 九种程序对照的实际结果

程序策略	收到的回答	结构合法	完整正确 /1,542
最新明确覆盖目标键	1,542	1,542	1,542
取最后展示行	1,542	1,542	72
按相同相对时效错配	1,542	1,542	606
只取最新文档	1,542	1,542	900
跨可见时刻取最大风速	1,542	1,542	42
当前气压填入预报风速	1,542	1,542	486
一直取最早覆盖来源	1,542	1,542	1,044
偶数交付步产生无效 JSON	1,542	780	780
偶数交付步缺失回答	780	780	780

这九种策略共 13,878 个计划机会。它们的“完整正确”是程序输出符合任务规则的数量，不是 LLM 的正确率。




图 3：程序对照用来验证公开可解性与评分区分度；图中不包含 P7 模型成绩。

12.3 错误程序为什么还能拿到不少正确项

“错误策略”表示该规则在一般情况下不能正确完成任务，不表示它对每道题必错。例如，最新文档恰好覆盖目标时，“只取最新文档”可能与合法策略一致。

当前气压策略对非数值查询保持不变，因此 486 个自然正确项有明确来源：26 个终止查询加 55 个未陈述查询，共 81 个，乘三方法和两重复身份为 486。不能为了让错误基线看起来更差而抹掉这些一致项。

缺失策略只有 780 个实际收到的答案，但计划分母仍为 1,542，另外 762 个计为失败。无效策略虽然收齐全部输出，也有 762 个不能拿到结构信用。这验证了固定分母处理。

最早来源策略还出现了 42 个“所有三个数值仍获字面支持，但当前版本错误”的回答。这说明真实资料也提供了区分字面支持与当前来源的机会。不过这是程序策略行为，不是已经观察到的 P7 LLM 失败。

12.4 上下文检查完成到什么程度

程序历史生成了 2,831 个不同请求，已用固定 Qwen3 tokenizer 计算实际长度。最长 prompt 为 16,059 tokens，加完整 8,192 输出预留，共 24,251，低于新任务共同上下文 32,768。

P7 没有为了塞进旧的 16,384 上下文而截掉来源行或错误历史。官方原文更长，任务版本因此使用新的上下文预算，并在未来实际后端预检后绑定运行配置。

但是程序历史的长度有限。未来真实模型可能生成更长的历史文本，每个实际请求仍需要重新做 tokenizer 检查。若溢出，应停止该次调度并按固定机会报告，而不是静默截短证据或挑选重试。

13. 为什么有 FAILED，却仍说 P6 已完成

13.1 模型采集完成，与整个作业全步骤成功不同

原始 P6 ACP 作业 pt-gxxtikov 的状态仍是 FAILED。它包含模型采集、报告与验证等步骤。模型采集器退出 0，已经保存全部 2,160 条回答；后面的原始 CPU 报告与验证步骤失败。

失败原因是审计程序对 EOS 的文本表现作了错误假设。EOS 可以理解为结束 token：后端保留了它的 token ID，但冻结设置要求最终显示文本不包含其停止标记。原审计却期待显示出这个标记，因此错误判定文本不一致。

另行冻结的 repeat_live_review 按实际绑定的渲染策略比较，核对了全部原始文本、答案提取、载体和分数。它没有重新生成模型答案，也没有改变 Gold 或评分语义。原作业的 FAILED、原始失败日志和捕获数据均保留。

所以准确的状态是：**模型矩阵已收齐并经独立 CPU 审阅完成核验，原始作业的后处理失败仍真实存在。**

13.2 这些验证工作具体带来什么信心

P6 的输出约束复核重放了 571,603 个最终输出/EOS token，未发现违反约束的 token。独立复制环境在工程、模型权重和网络不可用的条件下重建了相关报告。

最终验收绑定 9,434 个文件。它们能支持“这批保存结果与报告一致、可被复核”的结论，不能支持“模型已覆盖更多天气事件”或“统计显著”。工程证据与科学外推是不同层面。

13.3 P7 的已保留失败

P7 第一版复制 CPU 隔离 wrapper 在成功重建对象后退出 1，因为 urllib3 导入时尝试做一个本地 IPv6 能力探测，被隔离层拒绝。外层检查原先把它作为未预期网络行为。

v2 wrapper 仍然拒绝这个探测，只对确认的特定模块、函数和本地地址单独识别记账，没有放开网络或原始路径访问。初始失败、依赖证据与后续成功记录都保留。

另一个大整数回归用例曾暴露 scorer 把巨大整数转 float 时崩溃。修复后，整数仍作为语义错误保留，评分过程不崩溃；初始失败也保存。此类通用实现修复与手工改某一道 Gold 不同。

P7 当前通过 64 个新增测试和 26 个相关历史来源测试，共 90 个测试；验收绑定 327 个证据文件。本次制作详细报告重新核对了 P7 文件哈希与关键数字，但没有再次执行全部科学实验。

14. 目前到底完成了什么，还没完成什么

工作项	当前状态	可以怎样解释
受控任务语义与自动评分	已完成并用于实测	已能稳定组织明确规则的更新任务
P6 Qwen3-8B 配对重复矩阵	已收齐、独立审阅完成	有 2,160 条真实模型回答与完整失败分析
P6 多轮可靠性与来源归因	已完成	有检查点、轨迹、重复成功率和字段错误分类
官方 NHC 来源试点	已完成	12 份产品与原文位置可追溯，仍只有两个风暴
P7 原生任务、独立求解与评分	已离线验收	有 46 个目标、257 个查询和九种程序对照
P7 固定 tokenizer 上下文检查	程序历史范围内已完成	未来模型历史仍需运行时检查
四 worker 分配预览	已完成	只证明分配覆盖与归属正确，没有实际采集和加速比
原生 collector 与四 worker 全局聚合	待实现与验证	当前不能把离线预览当成可直接启动的模型执行器
P7 第一次真实模型实测	未开始	1,542 是计划机会，不能写成已获得答案
等信息 JSON/文本载体对照	待独立完成	还不能纯粹解释表示形式或内部记忆机制
匹配第二模型与更广来源	待设计后执行	旧 DeepSeek 与当前 Qwen 分数不构成匹配排行榜
跨灾种能力与业务价值验证	未完成	暂不能外推到所有极端天气或真实应急决策

如果要用一句话定位项目成熟度：**它已经有可靠的测量实现与一批真实模型结果，并且原生任务已经离线就绪；跨模型、跨事件与领域外推的证据仍需要继续补齐。**

这是一项有实证结果的 benchmark 研究进展，还不应仅凭当前矩阵宣称已经形成覆盖充分的通用极端天气模型排行榜。

15. 下一步怎样推进，每一步解决什么

15.1 第一优先级：原生采集器与独立聚合

现在缺的关键工程，是把冻结的 P7 任务接到真实模型，并能在多个 worker 部分失败时仍准确重建发生了什么。

新的 collector 要为每次请求保存原始输出、尝试身份和持久日志。它必须按各自轨迹的真实历史构造新请求，不能从程序对照或 Gold 初始化模型历史。

聚合器要独立重建每个 worker 的请求、载体、解析答案与分数，再按冻结的全局顺序合并。重复结果、未知尝试、缺失 worker、写入中断和归属变化都需要明确处理。一个不确定的提交不能通过静默再次生成掩盖。

完成标志应是：在模拟部分失败与重启情况时，机会不丢失、不重复计算、不被偷偷移交或补考，最终结果可独立重建。

15.2 第二优先级：后端测试与不生成的 H100 预检

正式采集前，要在实际 H100 上核验模型权重、tokenizer、推理后端、精度、上下文、结构约束和停止 token 到显示文本的行为。

这一步尤其要复用 P6 的 EOS 回归经验。token 列表和最终可见文本不是同一种对象，不能通过任意删特殊字符或空白来让审计“通过”。

预检不生成 benchmark 答案。预检的资源释放后，再启动最多四个正式 worker，确保同时最多四张 H100 的限制始终成立。

15.3 第三优先级：冻结第一次原生模型矩阵

项目	当前后续计划中的候选边界
模型	先沿用固定 Qwen3-8B，避免同时改变任务和模型
输入	P7 v1 完整公告，自然发行顺序的受控交付
方法与重复	三种方法、两个重复
机会数量	最多 1,542；每个计划位置一次尝试，不重试
上下文与输出	32768 / 完整输出预留 8192，须在实际预检后绑定
GPU	最多四张完整 H100，四个 TP=1 独立副本
时间与资源候选上限	四小时阶段截止；四卡同时分配时至多十六 H100 小时
heldout、付费 API、训练、LLM judge	当前这一步都不包含

这些是计划中待预检后写入新 live freeze 的边界，不是当前已经消耗的资源。不能修改离线 execution 的 generation flag 来把旧包临时变成实测包。

四个 worker 的预览分配如下。每个目标的所有方法、重复和检查点留在同一 worker 中。

Worker	目标 episode	计划回答	轨迹
0	12	390	72
1	12	390	72
2	11	384	66
3	11	378	66
合计	46	1,542	276

这能分散计算，但不意味着必然四倍加速。加载、不同 episode 长度、生成长度、批处理效率和最后等待最慢 worker 都会影响实际耗时。正式结果应分别报告阶段时间、各 worker 时间和 token 使用。

15.4 第四优先级：等信息载体、第二模型和更多独立来源

首次原生任务实测之后，优先回答三个互不替代的问题。

等信息载体实验研究表示形式：从同一保存前缀分支，保留相同事实与错误，只改变表达方式。它不是重新从头自主运行的轨迹成绩。

匹配第二模型研究模型适用性：使用同一任务、证据预算、方法定义、输出轨道与评分。旧版 DeepSeek 结果不能替代新任务上的匹配实测。

扩展独立来源研究事件外推：预先规定年份、产品、选择顺序和排除规则，按风暴分组，而不是继续堆叠同一风暴的模板。全部八个原定 heldout ID 继续保护；Francine 已明确作为开发来源，Ian 仍不能因计划中出现过就拿来做开发演示。

更多 GPU 主要解决已定义矩阵的计算速度，不能代替这三类研究设计。

16. 怎样判断研究贡献，以及怎样交给 ChatGPT 精简

16.1 目前最有证据支持的贡献表述

第一，建立了明确区分事实键、状态更新、当前来源与定位的可执行任务，使逐题人工评分和 LLM judge 不是主评分的必要环节。

第二，完成了真实模型实测，并表明数值正确、当前来源正确和重复整段可靠是不同的测量层面。P6 的同值旧来源错误和单点/轨迹成功率差距，提供了具体证据。

第三，已经把这一思路推进到官方预报原文，建立独立求解与程序对照，并保留自然覆盖缺口、未陈述和终止状态等情况。P7 的贡献当前是任务与测量工具验证，模型表现是下一步。

这些表述不等于已经证明项目具有文献上的首创性。与已有静态问答、证据问答、长上下文、动态知识和多轮状态 benchmark 的关系，还需逐篇比较输入、更新语义、引用规则、评分、数据来源与统计单位。

16.2 当前最需要主动承认的限制

任务规则可由程序求解，说明当前主要测试 LLM 执行和保持这些规则的可靠性；不能直接推导为深层气象推理。最新明确覆盖来源的选择规则，也需要与业务解释边界共同呈现。

独立风暴来源少，且公开 NHC 历史档案可能已在预训练中出现。目前没有证明彻底排除预训练曝光。P7 使用完整官方原文改善任务自然性，但两个风暴仍不足以代表广泛天气场景。

方法比较混合了信息量、长度与历史错误，只有一个匹配的当前实测模型和两个重复。它支持条件性的描述，不支持普遍方法排名或总体显著性。

自动 Gold 与多实现的对账减少了一些人工成本和实现风险，但共同的任务定义仍可能不合理。因此“无需逐题人工复核”与“无需研究者审查任务设计”必须分开。

16.3 一个适合你先讲清楚的口头版本

我们的 benchmark 关注极端天气资料不断更新时，LLM 能否维护正确状态，并把每个结论对应到当前来源。先用明确规则的受控任务建立自动评分体系，再进行真实模型实验。目前 P6 已完成 2,160 条 Qwen3-8B 回答，完整正确率为 86.2%。结果显示，即使数值正确，也可能引用旧版本；而单次回答较高的正确率，仍可能对应明显较低的重复整段成功率。

为了检验这种问题在自然资料中是否成立，我们进一步使用官方 NHC 预报原文，建立 P7 原生任务。它现在有 46 个目标、257 个查询，已经通过独立求解、评分与程序对照的离线验收。这里还没有模型成绩，1,542 是后续矩阵的计划机会。下一步要完成原生采集、多 worker 聚合和实际硬件预检，再开展首次原生模型实测，随后补充载体控制、第二模型和更多独立风暴。

16.4 给后续精简工具的约束

你可以把这份 Markdown 交给 ChatGPT，并附上下面的要求：

请基于这份详细说明，整理一份 15–20 分钟中文研究汇报。

优先解释研究问题、任务流程、已有实证发现、当前限制和下一步。

必须保留以下边界：

1. P6 的 2,160 条是真实模型回答；P7 程序诊断不是模型成绩。
 2. P7 已离线验收，但 1,542 仍是待模型作答的计划机会。
 3. 回答数、字段数、轨迹数、目标数和独立风暴数不能混用。
 4. pass^2 是两次都整段成功，不是 $\text{pass}@2$ 或单点概率平方。
 5. 三种方法都看到累计原始证据；不能说 snapshot 只看最新文档。
 6. 不把历史阶段画成模型能力提升曲线，不宣称普遍方法优劣。
 7. 当前研究使用已发布预报证据，不是评估真实天气预测技巧。
 8. P6 原始作业后处理失败被保留，独立 CPU 审阅完成重建。
- 为每页给出一个主结论、必要图表和可口述的解释，工程细节放附录。

17. 证据入口与阅读材料

17.1 这份说明怎样形成

P6 主结果、错误分类与配对表来自已验收评分和归因报告；真实错误例子从完整字段归因中按文件顺序选取第一条同值旧来源错误。P7 数字来自其离线验收、冻结数据和九份程序评分，327 个验收证据哈希已重新核对。

早期 P1-P5 作为历史里程碑，结合已有汇报数据与阶段结果说明。没有把历史版本重新评分，也没有把它们合并成一个统一模型分数。

本说明制作期间没有新增模型调用、GPU 作业或来源下载。PDF 中的教学例子明确标记为示意，实际模型例子与官方预报原文另行标注，不相互替代。

17.2 配套文件

文件	用途
本文 Markdown	可编辑的完整说明，便于交给 ChatGPT 精简
本文 PDF	从头阅读与分享，包含目录、页码、图表和代码节选
evidence/p6_actual_error.json	实际模型同值旧来源错误的完整记录
evidence/report_facts.json	本文使用的阶段数字、P6/P7 数据与来源哈希
P6 完成版演示 PDF	18 页，固定于 P6 结果与来源试点
P6 + P7 更新版演示 PDF	20 页，包含新增原生任务离线进展

主要研究文件位于 `development/disastertrace-next/disastertrace-starter/`：

- `artifacts/p6_live_v1/FINDINGS.md`：P6 最终结果与解释。
- `artifacts/p6_live_v1/reports/model_review_v2/scores.json`：P6 分数和配对记录。
- `artifacts/p6_live_v1/analysis/fields.jsonl`：全部字段归因。
- `artifacts/nhc_forecast_source_v1/review_v1/`：官方产品、解析与版本对。
- `artifacts/p7_forecast_task_v1/PROTOCOL.md`：原生任务完整契约。
- `artifacts/p7_forecast_task_v1/FINDINGS.md`：离线结果、限制与已保留失败。
- `artifacts/p7_forecast_task_v1/OFFLINE_ACCEPTANCE.json`：327 份证据的验收记录。
- `artifacts/p7_forecast_task_v1/NEXT_EXECUTION_PLAN.md`：下一次原生模型执行前的工程与资源计划。

涉及来源原文、Gold 和程序诊断的材料用于研究者复查，不应被当成额外资料导入未来模型的当前输入或历史载体。