

DisasterTrace

当天气证据更新， LLM 能否持续答对？

极端天气证据更新中的大语言模型可靠性评测
从受控状态维护，走向官方预报版本追踪



真实受控任务回答

2,160

三种方法 · 两个条件 · 两次重复

完整正确率

86.2%

1,861 / 2,160 个检查点完整正确

官方预报产品

12

来源试点完成 · 原生任务尚未实测

正确数字，还需要正确的当前来源

同值修订、作用域干扰和旧版重放，是不同的可靠性挑战。

01 / 初始记录 R1: 100 mph 回答 100 引用 R1	02 / 同值修订 R2 替代 R1 仍回答 100 引用更新为 R2	03 / 其他对象 R3: 120 mph 保留本目标的 100 仍引用 R2	04 / 旧记录再到达 再次交付 R1 保留当前状态 仍引用 R2
---	--	--	--

事实键：实体 + 有效时间/窗口 + 变量 + 测量种类 + 单位

旧记录可能字面支持数字，但不满足任务明确要求的当前版本引用。

三个测量层面：数值正确 / 来源版本正确 / 连续更新可靠

一条样本，是五个检查点上的状态维护

真实来源提供初始值；后续更新与交付明确标记为受控生成。

任务族	受控变化	正确行为
U1 局部更新	部分字段变化 含同值来源更新	更新目标、保留其余 刷新当前引用
U2 同窗口修订	同键修订、其他作用域 旧版本晚到重放	对齐事实键 选择当前版本
U3 支持恢复	字段支持尚未交付 之后到达	缺证时 unknown 到达后恢复 known

四字段完整状态

风速 mph / 气压 mb
纬度 / 经度

每个字段包含
status / value / evidence

3 来源 × 3 任务族 × 2 case × 2 branch = 36 条基础 episode

每条 episode 含 c0-c4 五个检查点；生成变体不增加独立风暴数。

共同证据相同，额外答案载体不同

每个检查点发送新请求；所有方法都看到截至当前已交付的累计原始证据。

snapshot 仅证据 不附加历史答案	structured_state 上轮状态 上一份结构合法的完整模型答案	answer_history 全部历史 此前全部结构合法的模型答案
---	---	--

合法但错误的答案原样进入后续载体；不使用 Gold 修正，轨迹各自隔离。

自动 Gold ↔ 独立公开求解器 → 确定性评分 → 独立 CPU 重建

无需逐题人工评分或 LLM judge；方法分差仍混合信息量、长度与历史错误的影响。

每轮迭代，解决一个测量问题

历史阶段用于解释设计如何推进；任务和设置不同，分数不能连成能力增长曲线。

- 01

稳定测量接口

自由输出的格式失败

P3：200/540 合法 → P4 独立结构轨：540/540 合法
- 02

识别语义失败

格式合法后仍会出错

P4：490/540 全对；P5 三因素压力：1,360/1,620 全对
- 03

改进比较控制

历史硬件与随机性差异

P6：同一硬件、配对条件、两次重复、2,160 回答
- 04

验证原生来源

官方预报能否严格对齐

12 份产品 / 95 行预报 / 49 对同有效时刻版本

当前成果：可执行任务 + 已验收实测 + 错误解释 + 官方来源试点

P6：一个边界清楚的配对重复矩阵

基础条件 base，对照 irrelevant_scope level 4；目标 Gold 保持一致。

条件

基础 episode

检查点

方法

重复

2

×

36

×

5

×

3

×

2

= 2,160

432 条轨迹 / 1,080 对检查点

固定 Qwen3-8B • BF16
一张完整 H100 • TP=1
上下文 16384 • 输出上限 8192

2,160/2,160 收齐且结构合法

thinking enabled • structure-only XGrammar
对应条件共享种子，方法与重复保留标识
无重试、替换或答案修补


36/36 格式屏通过；独立风暴来源仍为 3 个，不能把回答数当成独立事件数。

单次高准确率，仍可能伴随整段可靠性下降

Qwen3-8B 的描述性结果；两栏统计单位不同，请分别理解分母。


检查点完整正确率 (%)

每方法 / 每条件：360 个检查点



两次均五轮全对 (%)

每方法 / 每条件：36 条基础 episode



上轮状态：检查点 96.9% → 88.6%；两次均五轮全对 83.3% → 41.7%

数值正确，仍可能引用过期来源

来源版本是单独的测量维度：旧记录可以支持数字，却不满足当前版本规则。

123


值或状态错误

259

纯引用错误

382 处字段错误
/ 8,640 个字段机会

259 处纯引用错误的构成




116 / 259 个纯引用错误：数值相同，但引用的来源版本已经过期。

配对结果保留了两个方向的变化

曝光前输入与输出一致；曝光后净结果偏向下降，同时保留实际出现的改善。

c0、c1：432 对请求与最终文本全部一致，两边均完整正确。



曝光后：每方法 216 对检查点（c2–c4）

后续载体可能受前序输出影响：这是闭环轨迹比较，不能直接解释为固定载体的表示效应。

同一有效时刻，官方预报也会修订

来源试点：12 份产品 / 2 个风暴 / 95 行预报 / 49 对同有效时刻版本。

目标：Francine • 2024-09-10 18:00 UTC • 最大持续风速（KT）

公告 005

2024-09-09 21:00 UTC

75 KT

明确覆盖 • 原文第 31 / 32 行

公告 006

2024-09-10 03:00 UTC

没有该目标时刻
的明确预报行

不从相邻时刻插值补齐

公告 007

2024-09-10 09:00 UTC

70 KT

明确覆盖 • 原文第 25 / 26 行

拟定规则：在可见产品中，选择明确覆盖同一目标有效时刻的最新预报。

当前完成的是来源验证；前面的 86.2% 属于受控任务，不能用于这批原生预报。

当前结论的适用范围

已建立局部实证结果；领域外推与机制解释需要新的实验设计。

样本范围	3 个独立风暴来源 / 1 个匹配模型 / 2 次重复 2,160 是回答数；生成变体和检查点不是独立天气事件。
任务效度	当前受控任务可由公开的逐事实键程序求解 测量 LLM 执行明确更新规则的可靠性；尚未证明深层气象推理。
方法解释	载体同时改变信息量、长度与历史错误 当前方法排名是条件性的；等信息控制与第二模型尚待完成。

现有证据尚不支持跨灾种泛化、总体显著性或普遍的方法优劣结论。

下一步：先冻结原生任务，再扩大比较

把真实来源案例转化为公开可解、可评分、可独立重建的实验。

01	原生预报任务	明确绝对有效时刻、单位、缺失/终止状态与当前来源规则。
02	独立求解与评分	核对公开输入与 Gold；识别错误时间、旧引用和单位混淆。
03	等信息载体控制	同一保存状态生成 JSON / 文本；保留错误并测量 token 差异。
04	匹配模型与扩展来源	冻结矩阵后比较第二模型；按风暴分组增加独立开发来源。

接下来检验：来源与轨迹错误，能否在官方原文、更多模型和独立事件中重现？

附录 A | 完整主结果与分母

完整正确包含各字段状态、值、当前引用与研究动作；两次均五轮全对记为 pass^2。

条件	方法	R0 /180	R1 /180	检查点全对	五轮全对	两次均五轮全对
基础	仅证据	171	169	340/360 94.4%	55/72 76.4%	22/36 61.1%
基础	上轮状态	171	178	349/360 96.9%	64/72 88.9%	30/36 83.3%
基础	全部历史	144	135	279/360 77.5%	37/72 51.4%	13/36 36.1%
干扰	仅证据	152	157	309/360 85.8%	31/72 43.1%	11/36 30.6%
干扰	上轮状态	157	162	319/360 88.6%	43/72 59.7%	15/36 41.7%
干扰	全部历史	139	126	265/360 73.6%	34/72 47.2%	10/36 27.8%

pass^2 要求两次都整段成功；不是 pass@2、单次准确率平方或置信区间。

附录 B | 只看曝光后的检查点

c2-c4 切片补充主结果，不改变原先预定的完整轨迹分母。

方法	基础条件全对	干扰条件全对	净差：干扰 – 基础
仅证据	196/216 • 90.7%	165/216 • 76.4%	-14.4 个百分点
上轮状态	205/216 • 94.9%	175/216 • 81.0%	-13.9 个百分点
全部历史	135/216 • 62.5%	121/216 • 56.0%	-6.5 个百分点

全部历史的净差较小，但基础正确率也更低、两边都错更多；不能仅按下降幅度判断“更抗干扰”。

曝光前 432 对 + 曝光后 648 对 = 全部 1,080 对检查点。

附录 C | 原生预报任务的语义边界

官方来源事实与受控交付过程分开定义；不假定历史真实到达顺序。

维度	规则与限制
时间	issued_at、center_at、valid_at、retrieved_at 分开保存。 历史首次 available_at 和数值模式初始化时间仍未知。
覆盖	同一相对 lead 不等于同一绝对有效时刻。 较新产品无目标行时，不插值，也不自动删除先前明确行。
单位与状态	最大持续风速使用 KT，不能混入受控轨的 mph。 终止状态用显式状态与 null 表达，不当作零风速。
来源与独立性	双解析器核对同一产品，不是两个独立气象信息源。 49 对版本 = 23 对风速变化 + 24 对不变 + 2 对涉及终止状态。

12/12 产品入库、0 隔离；原生来源试点模型调用、人工 Gold 标注与 LLM judge 均为 0。

附录 D | 回答收齐与作业状态分别报告

原始失败保持可见；新冻结的 CPU 审阅程序重建原始回答、载体与分数。

事项	已核对事实
采集完成	2,160/2,160 回答到达，collector 退出 0；原始 ACP 作业仍为 FAILED。
审计缺陷	原审计错误期待 EOS 的文本标记，与冻结的 stop-token 渲染设置不符。
独立恢复	另冻 repeat_live_review；原 token、答案提取、载体、Gold 与评分语义未变。
重建与验收	复制 CPU 环境独立重建；既有最终验收核对 9,434 个绑定文件。
来源初始失败	最小快照漏了包导入依赖，网络请求前即失败；新快照补全依赖闭包。

原始作业：pt-gxxtikov；10 个 CPU 回归与 2 个已安装 vLLM 渲染测试支持审计修复。

所有 2,160 条运行文本符合绑定渲染策略；恢复报告未重新生成模型答案。

附录 E | 研究定位与方法追问

回答以当前证据为边界，明确研究贡献与待验证内容。

脚本就能求解，为什么还要评测 LLM？

程序提供公开可解性与规则基线。当前测量 LLM 执行这些规则的可靠性；原生文本轨仍应保留强程序基线，而非据此声称深层气象推理。

无需逐题人工复核，Gold 如何可信？

明确定义的任务语义、独立公开求解器和原文双解析交叉核对。避免逐题人工修补，但共同语义假设仍需研究审查。

structured_state 是否已经被证明最好？

它在当前矩阵的汇总指标上较高。信息量、长度与历史错误仍混杂，等信息控制、匹配第二模型和更多独立来源才支持更广解释。

结构约束是否把答案告诉了模型？

只提供输出形式，不给正确数值、引用或动作；但会改变解码分布，所以自由输出与受约束输出应分别报告。

附录 F | 样本、外推与后续执行

回答以当前证据为边界，明确研究贡献与待验证内容。

2,160 条回答是否等于 2,160 个独立案例？

它们来自 3 个独立风暴来源及其受控变体。检查点、分支和重复相关，本次不把全部回答当独立事件报告总体显著性。

这是否说明模型能够准确预测天气？

当前评测使用已发布证据的可靠性。未来若评估预报技巧，需另设实际观测真值、验证时效、误差指标与预报基线。

数据划分与预训练曝光如何处理？

按风暴分组，8 个原定 heldout ID 继续保护；Francine 明确作为开发来源。公开历史档案可能被预训练见过，目前不能声称完全排除污染。

四张 H100 是否已经实现加速？

四 worker 的离线分配已验证；实际多 worker 采集与聚合仍待完成。当前 2,160 回答由单 H100 产生，没有实测四倍加速比。