

DisasterTrace

当天气证据更新， LLM 能否持续答对？

极端天气证据更新中的大语言模型可靠性评测
受控实测完成，原生预报任务已通过离线验收



真实受控任务回答

2,160

三种方法 · 两个条件 · 两次重复

完整正确率

86.2%

1,861 / 2,160 个检查点完整正确

原生预报目标

46

257 个查询 · 待首次模型实测

正确数字，还需要正确的当前来源

同值修订、作用域干扰和旧版重放，是不同的可靠性挑战。

01 / 初始记录 R1: 100 mph 回答 100 引用 R1	02 / 同值修订 R2 替代 R1 仍回答 100 引用更新为 R2	03 / 其他对象 R3: 120 mph 保留本目标的 100 仍引用 R2	04 / 旧记录再到达 再次交付 R1 保留当前状态 仍引用 R2
---	--	--	--

事实键：实体 + 有效时间/窗口 + 变量 + 测量种类 + 单位

旧记录可能字面支持数字，但不满足任务明确要求的当前版本引用。

三个测量层面：数值正确 / 来源版本正确 / 连续更新可靠

P6：一条受控样本包含五个检查点

真实来源提供初始值；后续更新与交付明确标记为受控生成。

任务族	受控变化	正确行为
U1 局部更新	部分字段变化 含同值来源更新	更新目标、保留其余 刷新当前引用
U2 同窗口修订	同键修订、其他作用域 旧版本晚到重放	对齐事实键 选择当前版本
U3 支持恢复	字段支持尚未交付 之后到达	缺证时 unknown 到达后恢复 known

四字段完整状态

风速 mph / 气压 mb
纬度 / 经度

每个字段包含
status / value / evidence

3 来源 × 3 任务族 × 2 case × 2 branch = 36 条基础 episode

每条 episode 含 c0–c4 五个检查点；生成变体不增加独立风暴数。

P6 方法：共同证据相同，额外载体不同

每个检查点发送新请求；所有方法都看到截至当前已交付的累计原始证据。

snapshot

仅证据

不附加历史答案

structured_state

上轮状态

上一份结构合法的
完整模型答案

answer_history

全部历史

此前全部结构合法的
模型答案

合法但错误的答案原样进入后续载体；不使用 Gold 修正，轨迹各自隔离。

自动 Gold ↔ 独立公开求解器 → 确定性评分 → 独立 CPU 重建

无需逐题人工评分或 LLM judge；方法分差仍混合信息量、长度与历史错误的影响。

每轮迭代，解决一个测量问题

历史阶段用于解释设计如何推进；任务和设置不同，分数不能连成能力增长曲线。

- 01

稳定测量接口

自由输出的格式失败

P3：200/540 合法 → P4 独立结构轨：540/540 合法
- 02

识别语义失败

格式合法后仍会出错

P4：490/540 全对；P5 三因素压力：1,360/1,620 全对
- 03

改进比较控制

历史硬件与随机性差异

P6：同一硬件、配对条件、两次重复、2,160 回答
- 04

完成原生任务

官方文本的独立求解与评分

P7：46 个目标 / 257 个查询 / 9 种程序对照通过核验

当前成果：P6 模型实测 + 错误解释 + P7 原生任务离线验收

P6：一个边界清楚的配对重复矩阵

基础条件 base，对照 irrelevant_scope level 4；目标 Gold 保持一致。

条件

基础 episode

检查点

方法

重复

2

×

36

×

5

×

3

×

2

= 2,160

432 条轨迹 / 1,080 对检查点

固定 Qwen3-8B • BF16
一张完整 H100 • TP=1
上下文 16384 • 输出上限 8192

2,160/2,160 收齐且结构合法

thinking enabled • structure-only XGrammar
对应条件共享种子，方法与重复保留标识
无重试、替换或答案修补


36/36 格式屏通过；独立风暴来源仍为 3 个，不能把回答数当成独立事件数。

单次高准确率，仍可能伴随整段可靠性下降

Qwen3-8B 的描述性结果；两栏统计单位不同，请分别理解分母。


检查点完整正确率 (%)

每方法 / 每条件：360 个检查点



两次均五轮全对 (%)

每方法 / 每条件：36 条基础 episode



上轮状态：检查点 96.9% → 88.6%；两次均五轮全对 83.3% → 41.7%

数值正确，仍可能引用过期来源

来源版本是单独的测量维度：旧记录可以支持数字，却不满足当前版本规则。

123


值或状态错误

259

纯引用错误

382 处字段错误
/ 8,640 个字段机会

259 处纯引用错误的构成




116 / 259 个纯引用错误：数值相同，但引用的来源版本已经过期。

配对结果保留了两个方向的变化

曝光前输入与输出一致；曝光后净结果偏向下降，同时保留实际出现的改善。

c0、c1：432 对请求与最终文本全部一致，两边均完整正确。



曝光后：每方法 216 对检查点（c2-c4）

后续载体可能受前序输出影响：这是闭环轨迹比较，不能直接解释为固定载体的表示效应。

同一有效时刻，官方预报也会修订

P7 使用原有 12 份产品建立原生任务；来源仍为 Francine 与 Ida 两个风暴。

目标：Francine • 2024-09-10 18:00 UTC • 最大持续风速（KT）

公告 005

2024-09-09 21:00 UTC

75 KT

明确覆盖 • 原文第 31 / 32 行

公告 006

2024-09-10 03:00 UTC

没有该目标时刻
的明确预报行

不从相邻时刻插值补齐

公告 007

2024-09-10 09:00 UTC

70 KT

明确覆盖 • 原文第 25 / 26 行

P7 已冻结规则：在可见产品中，选择明确覆盖目标有效时刻的最新预报。

原生任务已离线验收、尚无模型实测；86.2% 仍仅属于 P6 受控任务。

P7：官方预报原文已形成独立任务

完整公告按发行顺序受控交付；每个目标对应一个风暴与绝对有效时刻。

原始候选查询

276

46 个目标 × 6 次交付

排除非未来查询

19

保留全部排除项与理由

实际纳入查询

257

176 数值 / 26 终止 / 55 未陈述

257 查询 × 3 方法 × 2 重复
= 1,542 个待模型作答机会

每条目标 episode 含 2-6 个检查点；
这里没有 P6 的 base / 干扰条件对照。

三个原生预报变量

纬度 / 经度 / 最大持续风速 KT
联合回答目标键、状态、数值与来源行


不插值、不推算未来气压、不继承动作规则。

1,542 是计划机会数；当前 P7 模型调用 = 0，不能作为已获得的模型样本。

P7：程序对照验证了任务可解与评分区分度

以下全部是确定性程序结果；不构成 LLM 成绩或随机重复可靠性估计。

完整正确回答 / 每策略固定 1,542 个机会



9 种程序策略共 13,878 个计划机会；错误策略的自然正确项与缺失机会均保留。

公开求解器独立解析模型可见文本；全部 257 个查询与编译器 Gold 一致。

当前结论的适用范围

已建立局部实证结果；领域外推与机制解释需要新的实验设计。

样本范围	P6：3 个风暴来源；P7：2 个风暴、0 次模型实测 P6 的回答数与 P7 的程序机会不合并；任务变体不增加独立天气事件。
任务效度	受控与原生任务均有独立公开程序求解器 程序正确性支持测量工具有效；原生任务中的 LLM 表现仍待实测。
方法解释	载体定义随任务版本冻结，不能跨版本混用 P7 保留无效/缺失历史的规则不同；等信息控制与匹配第二模型仍待完成。

现有证据尚不支持跨灾种泛化、总体显著性或普遍的方法优劣结论。

下一步：原生采集、独立聚合与首次模型实测

优先沿用固定 Qwen3-8B，建立新任务上的模型结果；第二模型与载体控制后续单独开展。

01	原生采集与聚合	新 collector、独立 worker 日志、一次性提交和失败保留；不能复用 P6 五轮假设。
02	后端核验与预检	离线测试后做不生成的 H100 预检；上下文拟为 32768，完整输出预留 8192。
03	新冻结的 1,542 机会	最多四张 H100、四个 TP=1 副本；每个目标的全部方法、重复和检查点归同一 worker。
04	控制与覆盖扩展	首次原生实测审计后，推进等信息载体、匹配第二模型与更多独立开发风暴。

四 worker 仅有离线分配：390 / 390 / 384 / 378 个机会；尚无调度与实测加速比。

附录 A | 完整主结果与分母

完整正确包含各字段状态、值、当前引用与研究动作；两次均五轮全对记为 pass^2。

条件	方法	R0 /180	R1 /180	检查点全对	五轮全对	两次均五轮全对
基础	仅证据	171	169	340/360 94.4%	55/72 76.4%	22/36 61.1%
基础	上轮状态	171	178	349/360 96.9%	64/72 88.9%	30/36 83.3%
基础	全部历史	144	135	279/360 77.5%	37/72 51.4%	13/36 36.1%
干扰	仅证据	152	157	309/360 85.8%	31/72 43.1%	11/36 30.6%
干扰	上轮状态	157	162	319/360 88.6%	43/72 59.7%	15/36 41.7%
干扰	全部历史	139	126	265/360 73.6%	34/72 47.2%	10/36 27.8%

pass^2 要求两次都整段成功；不是 pass@2、单次准确率平方或置信区间。

附录 B | P7 九种程序对照的完整分母

程序重复用于验证调度与核算；以下数量不计入真实 LLM 回答总量。

程序策略	实际收到	结构合法	完整正确 /1,542
最新明确覆盖目标键	1542	1542	1542
最后展示行	1542	1542	72
相对时效错配	1542	1542	606
只取最新文档	1542	1542	900
跨时刻取最大风速	1542	1542	42
当前气压写入预报风速	1542	1542	486
最早覆盖来源	1542	1542	1044
偶数交付步无效 JSON	1542	780	780
偶数交付步缺失回答	780	780	780

错误程序在部分查询上仍然正确；保留自然一致项，才能看清任务的实际区分度。

附录 C | P7 原生契约与上下文边界

任务专用语义已冻结；与 P6 的字段、检查点长度和历史载体规则分别报告。

维度	已冻结规则 / 已核对边界
时间与来源	精确绝对未来有效时刻；最新可见且明确覆盖目标的产品。 历史 available_at 与初始化时间未知，不推断旧预报的业务有效性。
数值与状态	纬度、经度为 deg；最大持续风速为 KT。numeric / DISSIPATED / ABSORBED / not_stated；终止或未陈述为 null，不插值、不赋零。
原生载体	structured_state：上一答案或无效/缺失标记；answer_history：此前原始最终文本与缺失标记。累计原文一致，绝不导入程序答案。
查询与上下文	目标目录来自整批已声明来源，未来公告正文与 Gold 不进入请求。 2,831 个程序请求已核对；最大 $16,059 + 8,192 = 24,251 < 32,768$ 。

程序载体通过上下文检查，不代表任意未来模型历史都不会溢出；实测必须逐请求检查。

附录 D | P6 实测与 P7 离线验收分别核对

软件验证支持报告可复核；历史失败保留，不能把恢复后的报告改写为原作业全成功。

范围	已确认事实
P6 实测	2,160 条回答收齐；原始作业因 EOS 文本审计缺陷保持 FAILED。 另冻 CPU 审阅恢复报告，原 token、答案、载体、Gold 与评分语义未变。
P7 软件验证	64 个新增 + 26 个相关历史测试通过；九种程序对照完整。 复制 CPU CLI 重建数据、请求、分数与 token 计数；模型与 GPU 作业为 0。
P7 初始失败	初始隔离 wrapper 在重建成功后因 urllib3 的本地 IPv6 探测退出 1。 v2 仍拒绝该探测，仅单独识别记账；原失败与限制保持可见。
验收与保全	P7 验收绑定 327 份证据；既有 P6 两份验收已重新核对。 P6 的 5,703 与 9,434 个条目存在重叠，不能相加为唯一文件数。

P6 模型结果已完成；P7 原生任务已离线验收；P7 模型采集与四卡聚合仍待实现。

附录 E | 研究定位与方法追问

回答以当前证据为边界，明确研究贡献与待验证内容。

脚本就能求解，为什么还要评测 LLM？

P6 测量 LLM 执行明确规则的可靠性；P7 已有独立公开程序基线。程序正确性支持工具有效，真实原文上的 LLM 表现仍待实测。

无需逐题人工复核，Gold 如何可信？

明确定义的任务语义、独立公开求解器和原文双解析交叉核对。避免逐题人工修补，但共同语义假设仍需研究审查。

structured_state 是否已经被证明最好？

它在当前矩阵的汇总指标上较高。信息量、长度与历史错误仍混杂，等信息控制、匹配第二模型和更多独立来源才支持更广解释。

结构约束是否把答案告诉了模型？

只提供输出形式，不给正确数值、引用或动作；但会改变解码分布，所以自由输出与受约束输出应分别报告。

附录 F | 样本、外推与后续执行

回答以当前证据为边界，明确研究贡献与待验证内容。

2,160 条回答是否等于 2,160 个独立案例？

它们来自 3 个独立风暴来源及其受控变体。检查点、分支和重复相关，本次不把全部回答当独立事件报告总体显著性。

这是否说明模型能够准确预测天气？

当前评测使用已发布证据的可靠性。未来若评估预报技巧，需另设实际观测真值、验证时效、误差指标与预报基线。

数据划分与预训练曝光如何处理？

按风暴分组，8 个原定 heldout ID 继续保护；Francine 明确作为开发来源。公开历史档案可能被预训练见过，目前不能声称完全排除污染。

四张 H100 是否已经实现加速？

P7 已离线分配 390/390/384/378 个机会；采集与聚合仍待实现。
P6 的 2,160 回答由单 H100 产生，目前没有四卡实测加速比。